Grafici a scatola con i baffi (boxplot)

Il modo più semplice per generare i **grafici a scatola con i baffi** (box-and-whiskers plot, denominazione in genere abbreviata in **boxplot**) è impiegare la funzione **boxplot()** inclusa nel pacchetto base di **R** che utilizza i seguenti criteri di rappresentazione [1]:
→ le **scatole** (box) includono il 50% delle osservazioni;
→ il bordo inferiore delle scatole corrisponde al 25° percentile o primo quartile (Q_1);
→ la linea interna alle scatole corrisponde al 50° percentile o secondo quartile (Q_2) ovvero alla mediana;
→ il bordo superiore delle scatole corrisponde al 75° percentile o terzo quartile (Q_3);
→ i **baffi** (whiskers) corrispondono al valore minimo (baffo inferiore) e al valore massimo (baffo superiore) osservati dopo avere escluso gli outliers (vedi sotto);
→ la differenza interquartile [2] viene definita come IQR = $Q_3 - Q_1$ ovvero come differenza tra il valore corrispondente al terzo quartile (Q_3) e il valore corrispondente al primi quartile (Q_1);
→ i valori inferiori a Q_2 - 1.5 · IQR e i valori superiori a Q_2 + 1.5 · IQR sono considerati **outliers** (dati anomali o dati aberranti), sono esclusi dal computo dei valori minimo e massimo (vedi sopra), e sono riportati come punti singoli separati.

I boxplot forniscono una analisi non parametrica dei dati complementare a quella numerica. Qui li impieghiamo per effettuare l'analisi della concentrazione degli eritrociti (globuli rossi) nel sangue rilevata in 202 atleti australiani riportata nella colonna/variabile **rcc** della tabella **ais** inclusa nel pacchetto **DAAG**. Accertatevi di avere installato il pacchetto o in alternativa procedete come indicato in [3]. La conclusione?

Con **R** è possibile realizzare grafici a scatola con i baffi con una sola e semplicissima riga di codice!

Iniziamo con queste quattro righe di codice, copiatele e incollatele nella `Console di R` e premete ↵ `Invio`:

```
# GRAFICI A SCATOLA CON I BAFFI suddivisi in base a un fattore
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
windows() # apre e inizializza una nuova finestra grafica
#
boxplot(rcc~sport, data=ais, horizontal=FALSE, main="Eritrociti per sport praticato",
xlab="Sport praticato", ylab="Eritrociti in 10^12/L", notch=FALSE, col="yellow") #
eritrociti per ciascuno sport praticato
#
```

Le prime due righe si limitano a:
→ caricare con la funzione **library()** il pacchetto **DDAG** che include il set di dati **ais**;
→ aprire una finestra grafica con la funzione **windows()**.

Per tracciare il boxplot viene impiegata una sola riga di codice con la funzione **boxplot()** e con questi argomenti:
→ **rcc~sport** che indica che la rappresentazione degli eritrociti sotto forma di boxplot deve essere effettuata aggregando (**~**) i valori della variabile eritrociti (**rcc**) nei sottoinsiemi corrispondenti ai valori del fattore/variabile **sport** (`B_Ball`, `Field`, `Gym`, `Netball`, `Row`, `Swim`, `T_400m`, `T_Sprnt`, `Tennis`, `W_Polo`);
→ **data=ais** che specifica il nome della tabella che contiene la variabile **rcc** e la variabile **sport** - notare che questo argomento è superfluo se vi riferite alle variabili della tabella **ais** indicandole con il nome completo **ais$***nomedellavariabile*, ovvero nel nostro caso **ais$rcc**, **ais$sex**, **ais$sport**, e così via;

→ **horizontal=FALSE** che indica che i boxplot devono essere orientati verticalmente;
→ **main="..."** che riporta il titolo del grafico;
→ **xlab="..."** che riporta l'etichetta da applicare all'asse `x` delle ascisse;
→ **ylab="..."** che riporta l'etichetta da applicare all'asse `y` delle ordinate:
→ **notch=FALSE** che esclude dai boxplot la rappresentazione dell'incisura che riporta i limiti di confidenza al 95% della mediana dei valori osservati;
→ **col="..."** che definisce il colore di riempimento dei boxplot.

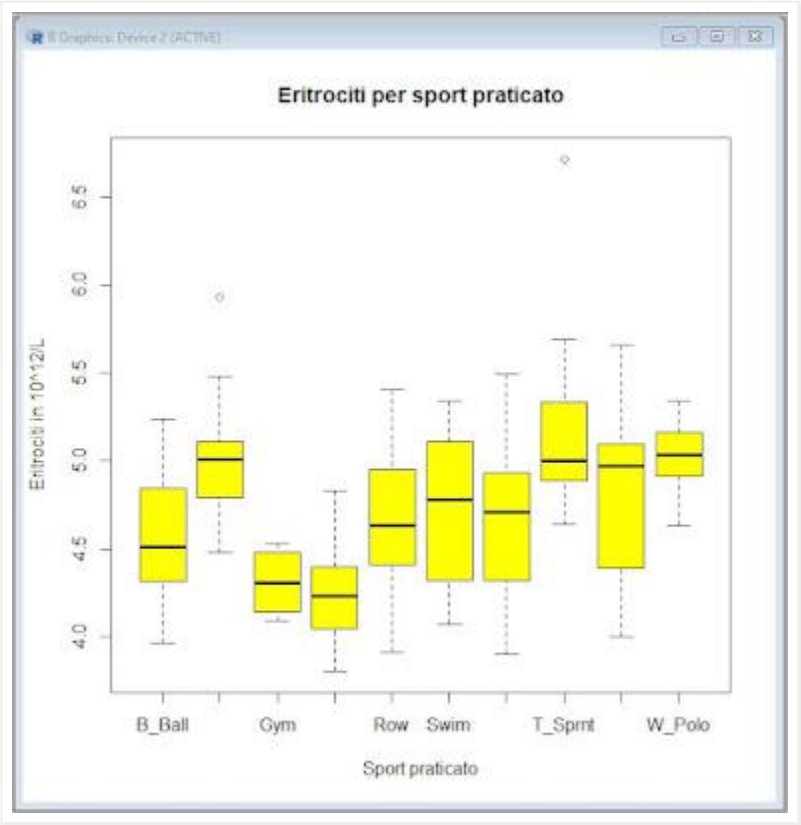

Sull'asse orizzontale apparentemente non c'è spazio sufficiente per riportare le denominazioni di tutti gli sport: ma se "afferrate" il lato sinistro della finestra con il mouse ed estendete la finestra grafica in orizzontale vedete comparire le denominazioni mancanti.

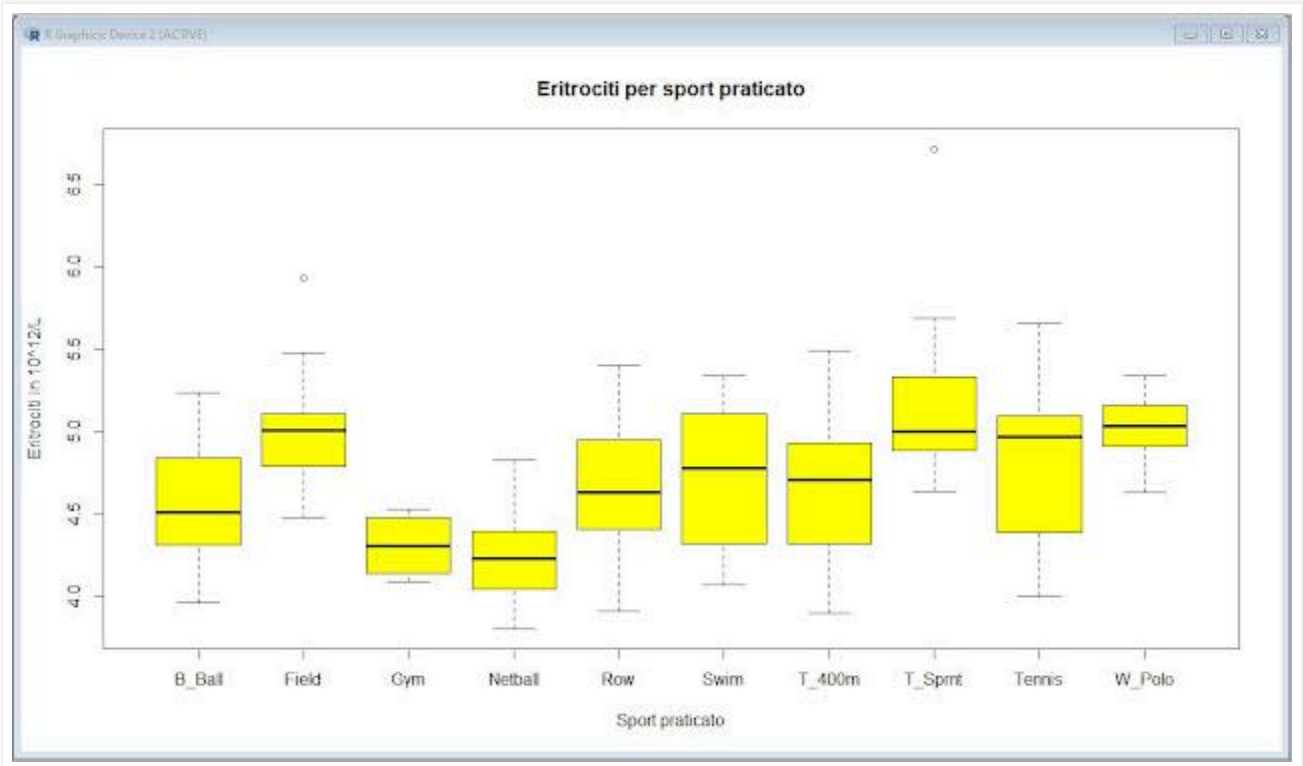

In questo secondo script rielaboriamo i dati aggregando i valori per sesso con l'argomento **rcc~sex**:

```
# GRAFICI A SCATOLA CON I BAFFI con i limiti di confidenza della mediana
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
windows() # apre e inizializza una nuova finestra grafica
#
boxplot(rcc~sex, data=ais, horizontal=FALSE, main="Eritrociti per sesso", xlab="Sesso",
ylab="Eritrociti in 10^12/L", notch=TRUE, col="green") # eritrociti per sesso
#
```

Impiegando l'argomento **notch=TRUE** ora sui lati dei boxplot sono comparse le tacche (**notch**) o se preferite le incisure che rappresentano i limiti di confidenza al 95% della mediana.

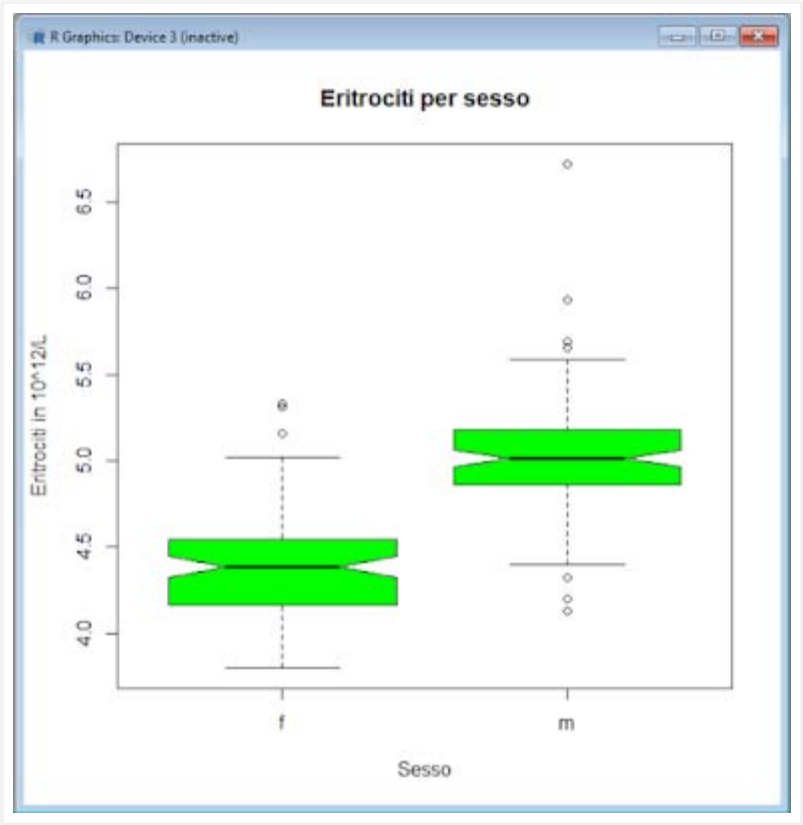

Questo corrisponde ad un test per la significatività della differenza tra le mediane: se le tacche o incisure di due boxplot non si sovrappongono, pur sovrapponendosi in parte le distribuzioni dei dati, come in questo caso, la conclusione è che le mediane delle due distribuzioni differiscono significativamente.

Il fatto interessante è quindi che una rappresentazione grafica può essere impiegata non solo per effettuare una *analisi esplorativa dei dati*, ma addirittura per effettuare un *test statistico* (un confronto tra mediane) che ci conferma il fatto che la mediana della concentrazione degli eritrociti nelle atlete è inferiore a quella dagli atleti (è all'incirca di $4.4 \cdot 10^{12}$/L contro $5.0 \cdot 10^{12}$/L) e che la differenza tra le mediane, all'incirca di $0.6 \cdot 10^{12}$/L, è statisticamente significativa come risulta dal confronto fra i due boxplot.

Da notare che quando nella funzione **boxplot()** si pone l'argomento **notch=TRUE** potrebbe comparire nella `Console di R` un messaggio che avverte che in alcuni casi le incisure sono uscite dai bordi della scatola e che suggerisce di valutare l'opportunità di sostituire l'argomento con **notch=FALSE**.

Questo vi accadrà quando eseguite questo terzo script, che applica l'argomento **notch=TRUE** ai boxplot differenziati per sport:

GRAFICI A SCATOLA CON I BAFFI con i limiti di confidenza della mediana
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
windows() # apre e inizializza una nuova finestra grafica
#
boxplot(rcc~sport, data=ais, horizontal=FALSE, cex.axis=0.8, las=2, main="Eritrociti per sport praticato", xlab="Sport praticato", ylab="Eritrociti in 10^12/L", notch=TRUE, col="green") # eritrociti per ciascuno sport praticato
#

In questo caso il grafico

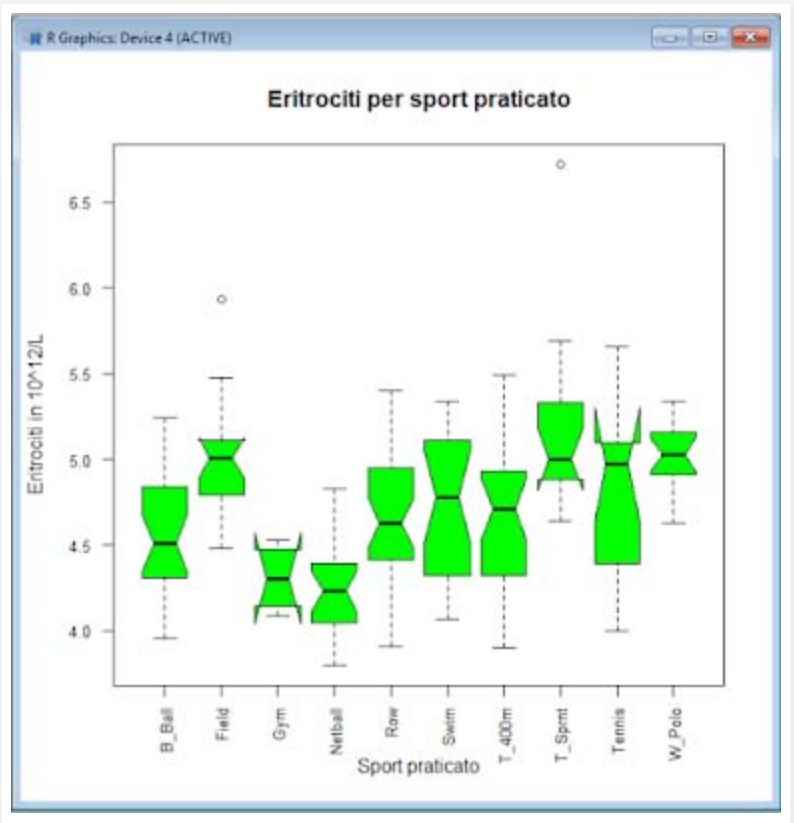

evidenzia la comparsa del problema per gli sport `Field`, `Gym`, `T_sprnt`, `Tennis` e nella `Console di R` viene riportato questo messaggio:

```
> boxplot(rcc~sport, data=ais,  horizontal=FALSE, cex.axis=0.8, las=2,
main="Eritrociti per sport praticato", xlab="Sport praticato", ylab="Eritrociti in
10^12/L", notch=TRUE, col="green") # eritrociti per ciascuno sport praticato
Messaggio di avvertimento:
In (function (z, notch = FALSE, width = NULL, varwidth = FALSE,  :
alcune tacche sono andate fuori dai cardini ('box'): potresti impostare notch=FALSE
> #
```

Il problema è causato dal fatto che per gli sport in questione il numero delle osservazioni è troppo ridotto. In questi casi vi sono solamente due modi per superare il problema:
→ mettere l'argomento **notch=FALSE**, come consigliato nella nota "`potresti impostare notch=FALSE`", e quindi rinunciare al "test grafico" di significatività;
→ aumentare adeguatamente, sempre che sia possibile farlo, il numero delle osservazioni.

Da notare che nella funzione **boxplot()** sono stati aggiunti due argomenti che consentono di ricavare lo spazio necessario per riportare sotto ai boxplot degli eritrociti le denominazioni degli sport senza dover ridimensionare la finestra grafica:
→ l'argomento **cex.axis=0.8** che riduce lievemente la dimensione dei caratteri;
→ l'argomento **las=2** che ruota verticalmente le etichette.

Ora copiate questo script, incollatelo nella `Console di R` e premete `↵ Invio`:

```
# GRAFICI A SCATOLA CON I BAFFI con due grafici nella stessa immagine
#
library(DAAG) # carica il pacchetto DAAG incluso il set di dati ais
windows() # apre e inizializza una nuova finestra grafica
par(mfrow=c(1,2)) # due grafici in una riga e due colonne
#
boxplot(ais$pcBfat~ais$sport, horizontal=TRUE, boxwex=0.4, cex.axis=0.8, las=1,
xlab="Grasso corporeo in %", ylab="Sport praticato", notch=FALSE, col="yellow") # valori
della percentuale di grasso corporeo aggregati per sport
#
boxplot(ais$wt~ais$sport, horizontal=TRUE, boxwex=0.4, cex.axis=0.8, las=1,
xlab="Peso corporeo in kg", ylab="Sport praticato", notch=FALSE, col="yellow") # [2]
valori del peso corporeo aggregati per sport
#
```

In questo caso, per riportare due grafici affiancati:
→ con **par(mfrow=c(1,2))** è stata predisposta la suddivisione della finestra in **1** riga e **2** colonne;
→ i boxplot sono riportati in orizzontale (**horizontal=TRUE**);
→ la larghezza dei box è stata ridotta (**boxwex=0.4**);
→ è impiegato l'argomento **cex.axis=0.8** che riduce lievemente la dimensione dei caratteri;
→ le etichette delle ascisse sono riportate in orizzontale (**las=1)**,
→ non vengono riportate le incisure (**notch=FALSE**) che rappresentano i limiti di confidenza al 95% della mediana.

Inoltre qui, in assenza dell'argomento **data=ais**, nella funzione **boxplot()** sono stati riportati per intero – cioè con il prefisso **ais$** che indica la tabella che le contiene – i nomi della variabili.

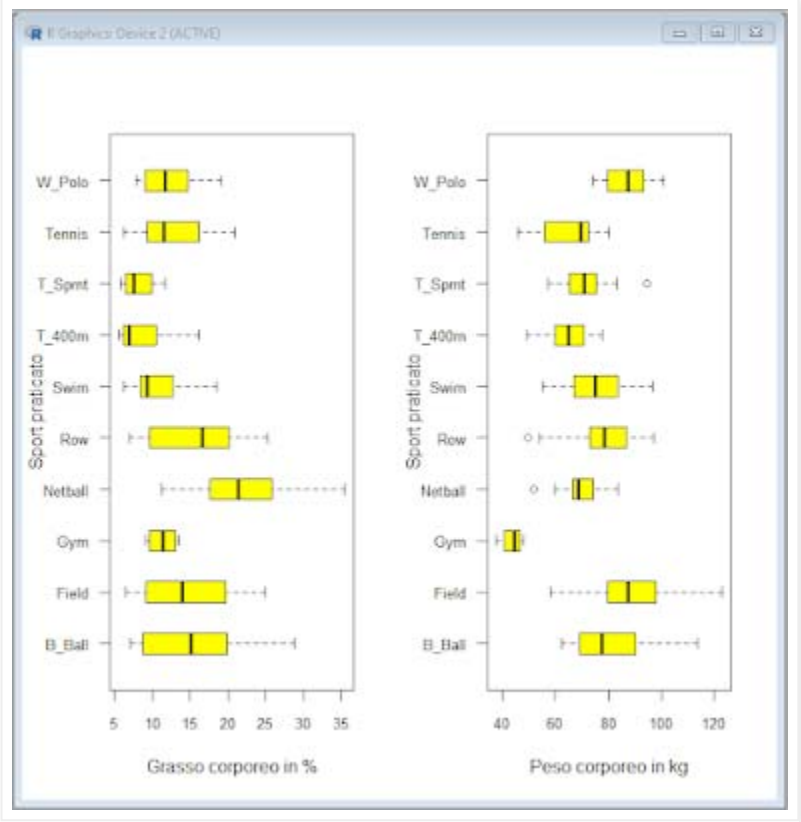

Con quest'ultimo script riportiamo in un unico grafico i boxplot suddivisi in base a due fattori: sport e sesso. Questa volta la novità consiste in una legenda liberamente posizionabile: dopo avere tracciato i grafici separati per sport praticato e per sesso, lo script rimane in attesa. A questo punto bisogna posizionare il mouse dove si vuole che compaia la legenda [4] e fare `click` con il tasto sinistro del mouse per farla comparire e terminare lo script.

```
# GRAFICI A SCATOLA CON I BAFFI suddivisi in base a due fattori
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
windows() # apre e inizializza una nuova finestra grafica
#
boxplot(rcc~sex+sport, data=ais, horizontal=FALSE, boxwex=0.4, cex.axis=0.8, las=2,
main="Eritrociti per sport praticato e per sesso", xlab="", ylab="Eritrociti in 10^12/L",
notch=FALSE, col=c("green", "yellow")) # eritrociti per ciascuno sport praticato
#
legend(locator(1), legend=c("sesso f","sesso m"), fill=c("green", "yellow")) # posiziona la legenda
#
```

Il codice non consente di spostare la legenda. Se non si è soddisfatti della sua posizione, è necessario rieseguire l'intero blocco di codice e fare nuovamente `click` con il tasto sinistro del mouse nel punto in cui si vuole posizionare la legenda.

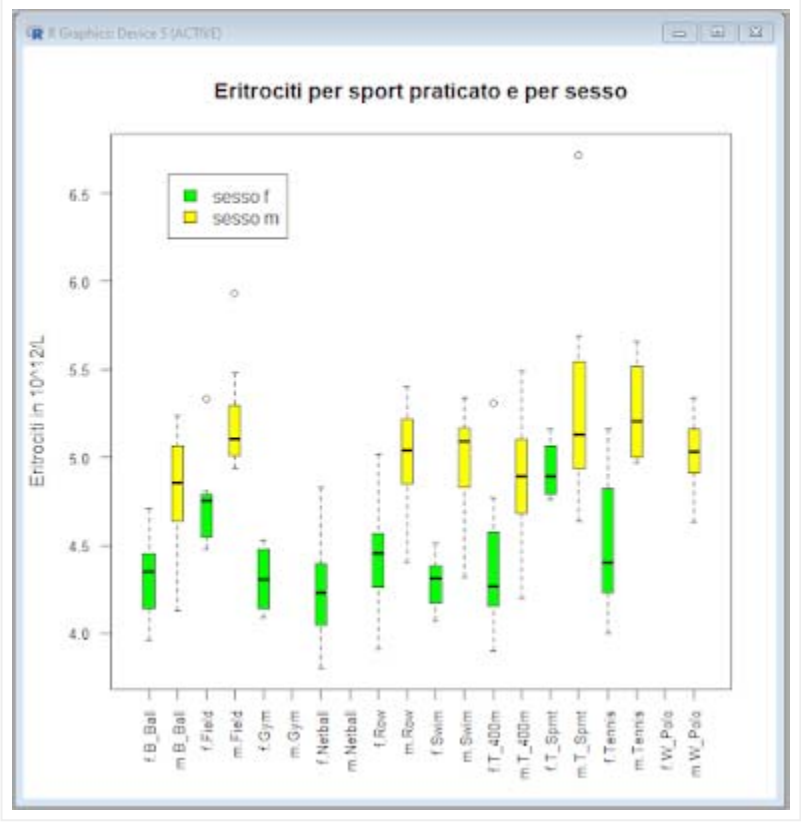

Nella funzione **boxplot()** sono ora impiegati tre argomenti per risolvere il problema dello spazio necessario per riportare nella finestra grafica i boxplot degli eritrociti per tutti gli sport e per entrambi i sessi:
→ l'argomento **boxwex=0.4** che riduce la larghezza dei boxplot;
→ l'argomento **cex.axis=0.8** che riduce lievemente la dimensione dei caratteri;
→ l'argomento **las=2** che ruota verticalmente le etichette.

La legenda viene realizzata mediante la funzione **legend()** impiegando come argomenti:
→ la funzione **locator()** che resta in attesa, legge la posizione del cursore grafico quando viene fatto click con il tasto sinistro del mouse, e posiziona la legenda;
→ **legend=** che specifica le due righe di testo che compaiono nella legenda;
→ **fill=** che determina la comparsa accanto alle righe di testo di due quadrati dei colori specificati.

Chiudo con tre suggerimenti che potrebbero essere utili:
→ trovate come combinare adeguatamente in un'unica immagine più grafici a scatola con i baffi nel post Inserire più grafici nella stessa immagine;
→ potete combinare i grafici a scatola con i baffi con il kernel density plot dei dati impiegando i grafici a violino (violin plot) [5];
→ quando i dati sono pochi, e preferite conservare il dettaglio dei singoli valori, potete impiegare in alternativa i grafici a punti (dotplot).

Infine se siete interessati ad una estetica alternativa potete impiegare le funzioni incluse nel pacchetto **ggplot2** [6].

---

[1] Digitate **help(boxplot)** nella `Console di R` per la documentazione della funzione **boxplot()**.

[2] In italiano oltre che differenza interquartile si impiega anche scarto o ampiezza o range interquartile, in inglese si impiega Inter Quartile Range, da cui IQR.

[3] Vedere il post Il set di dati ais nel quale trovate anche come caricare i dati della tabella senza impiegare il pacchetto **DAAG**.

[4] Più precisamente fare click con il tasto sinistro del mouse nel punto in cui si vuole posizionare l'angolo superiore sinistro della legenda.

[5] Richiede l'installazione del pacchetto aggiuntivo **ggplot2**.
https://cran.r-project.org/web/packages/ggplot2/index.html

[6] Vedere il post Grafici a scatola con i baffi (boxplot) con ggplot.