Grafici a scatola con i baffi (boxplot) con ggplot

I **grafici a scatola con i baffi** (o *box plot* o *boxplot*) sono una delle molte rappresentazioni grafiche dei dati che si possono realizzare con il pacchetto **ggplot2**. Come con gli altri post analoghi lo scopo è aiutare a rompere il ghiaccio con le funzioni di questo pacchetto, che possono risultare ostiche quando le si affronta per la prima volta.

Oltre al pacchetto **ggplot2** [1] dovete accertarvi di avere installato – o dovete scaricare anche – il pacchetto **DAAG** [2] che contiene il set di dati **ais** impiegati nell'esempio, il pacchetto **gridExtra** che consente di combinare i grafici in una sola figura e il pacchetto **forcats** per l'ordinamento in base alla mediana dei gruppi.

Copiate e incollate nella `Console di R` questo script e premete `↵ Invio`.

```
# BOXPLOT con ggplot
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
library(gridExtra) # carica il pacchetto per combinare i grafici in una sola figura
#
# boxplot dell'emoglobina per sesso
plot1 <- ggplot(ais, aes(x=sex, y=hg)) + geom_boxplot(aes(fill=sex))
#
# riposiziona la legenda in basso
plot2 <- ggplot(ais, aes(x=sex, y=hg)) + geom_boxplot(aes(fill=sex)) +
theme(legend.position="bottom")
#
# aggiunge etichette degli assi e titolo
plot3 <- ggplot(ais, aes(x=sex, y=hg)) + geom_boxplot(aes(fill=sex)) + xlab("Sesso") +
ylab("Emoglobina (g/dL)") + ggtitle("Boxplot per sesso")
#
# centra il titolo e personalizza la legenda
plot4 <- ggplot(ais, aes(x=sex, y=hg)) + geom_boxplot(aes(fill=sex), notch=TRUE) +
xlab("Sesso") + ylab("Emoglobina (g/dL)") + ggtitle("Boxplot per sesso") +
theme(plot.title=element_text(hjust=0.5)) + labs(fill="Legenda") +
scale_fill_hue(labels=c("f=donna", "m=uomo"))
#
# combina i grafici in una sola figura
grid.arrange(plot1, plot2, plot3, plot4, nrow=2, ncol=2)
#
```

Dopo avere caricato i pacchetti necessari, sono generati quattro boxplot che sono salvati separatamente per essere al termine (solo per semplicità) combinati in una sola figura.

Per realizzare il primo grafico (**plot1**) viene impiegata innanzitutto la funzione **ggplot()** – che inizializza l'oggetto al quale sono collegate con il segno più [**+**] le successive funzioni, che sviluppano la grafica – che prevede:
→ come primo argomento il nome della tabella che contiene i dati (**ais**);
→ come secondo argomento la funzione **aes()** che specifica di riportare in ascisse (**x=**) la variabile (fattore) sesso **sex** e in ordinate (**y=**) la variabile (numerica) **hg** che rappresenta la concentrazione di emoglobina espressa in grammi per decilitro di sangue (g/dL).

Alla funzione **ggplot()** viene quindi collegata con il segno più [**+**] la funzione **geom_boxplot()** che realizza il grafico a scatola con i baffi specificando per il colore di riempimento (**fill**) dei boxplot una gamma di colori automatica con un colore differente per ciascun sesso (**sex**).

Da notare subito che questa è la struttura base che rimane identica in tutti e quattro i grafici realizzati, che si differenziano tra loro per le componenti grafiche via via aggiunte.

Il secondo grafico (**plot2**) quindi riprende tal quale la precedente struttura base e aggiunge semplicemente, tramite la funzione **theme()**, il posizionamento della legenda (**legend.position**) in basso sotto al grafico (**"bottom"**).

Nel terzo grafico (**plot3**) viene eliminato il riposizionamento della legenda che viene pertanto lasciata nella posizione laterale prevista di default, quindi:
→ con la funzione **xlab()** viene aggiunta l'etichetta dell'asse delle ascisse;
→ con la funzione **ylab()** viene aggiunta l'etichetta dell'asse delle ordinate;
→ con la funzione **ggtitle()** viene riportato in alto un titolo per il grafico.

Il quarto grafico (**plot4**) riprende in toto le funzioni del terzo grafico e in aggiunta:
→ con **notch=TRUE** riporta sui box i limiti di confidenza al 95% della mediana;
→ con l'argomento **plot.title** della funzione **theme()** centra il titolo;
→ con **labs()** riporta l'intestazione della legenda;
→ con **scale_fill_hue()** riporta nella legenda le etichette che identificano i dati.

Infine con la funzione **grid.arrange()** i quattro grafici sono combinati in un'unica figura.

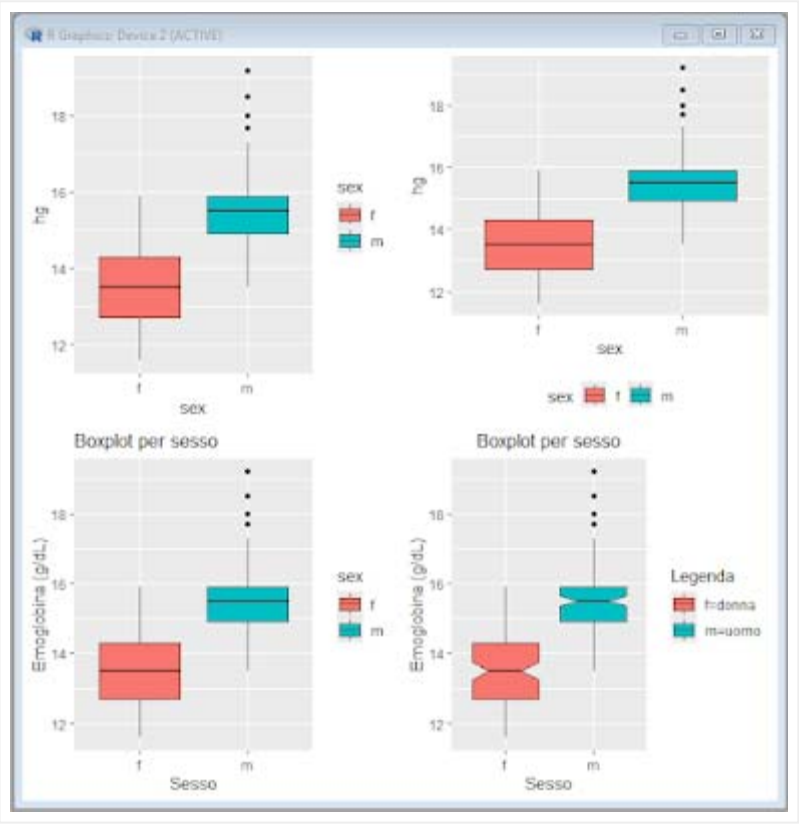

Copiate e incollate nella `Console di R` questo secondo script e premete ↵ `Invio`.

```
# BOXPLOT con ggplot
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
library(gridExtra) # carica il pacchetto per combinare i grafici in una sola figura
library(forcats) # carica il pacchetto per l'ordinamento in base alla mediana
#
# boxplot dell'emoglobina per sport con dotplot
plot1 <- ggplot(ais, aes(x=sport, y=hg)) + geom_boxplot(aes(fill=sport)) +  ylim(10, 20)
+ theme(legend.position="none") + geom_dotplot(binaxis='y', stackdir='center',
binwidth=0.3, color="black", fill="grey")
#
# boxplot con incisura e ordinati in base alla mediana
plot2 <- ggplot(ais, aes(x=fct_reorder(sport, hg, median), y=hg)) +
geom_boxplot(aes(fill=sport), notch=TRUE) +  ylim(10, 20) +
theme(legend.position="none")
#
# boxplot per sesso con etichette in verticale e ampiezza dei boxplot ridotta
plot3 <- ggplot(ais, aes(x=fct_reorder(sport, hg, median), y=hg)) +
geom_boxplot(aes(fill=sex), width=.75) +  ylim(10, 20) +
theme(legend.position="none") + theme(axis.text.x=element_text(angle=90, hjust=1))
#
# unisce i grafici in una sola figura
grid.arrange(plot1, plot2, plot3, nrow=3, ncol=1)
#
```

Il primo grafico (**plot1**) rispetto a quanto riportato nello script precedente prevede queste modifiche:
→ il fattore sesso viene sostituito con il fattore **sport**;
→ con la funzione **ylim()** viene personalizzata la scala delle ordinate;
→ con il valore **"none"** dell'argomento **legend.position** della funzione **theme()** viene eliminata la legenda;
→ con la funzione **geom_dotplot()** ai boxplot sono sovrapposti i grafici a punti (dotplot) centrati (**'center'**) lungo l'asse delle ordinate (**'y'**) con un diametro oppertunamente ridotto (**0.3**), tracciati in nero (**"black"**) con riempimento in colore grigio (**"grey"**).

Eliminata la parte più verbosa rappresentata dai grafici a punti (dotplot) sovrapposti, i grafici seguenti sono realizzati con piccole modifiche del codice.

Nel secondo grafico (**plot2**) viene eliminato il riposizionamento della legenda che viene pertanto lasciata nella posizione laterale prevista di default, quindi:
→ con la funzione **fct_reoder()** i box per **sport** sono riportati ordinati in base alla mediana (**median**) dell'emoglobina (**hg**);
→ con **notch=TRUE** viene riportata in ciascun box l'incisura che rappresenta i limiti di confidenza al 95% della mediana. Questo fornisce un test per la significatività della differenza tra le mediane: se le tacche o incisure di due boxplot non si sovrappongono, pur sovrapponendosi in parte le distribuzioni dei dati, le mediane delle due distribuzioni differiscono significativamente. Da notare che nella `Console di R` compare quattro volte un messaggio che avverte che le incisure sono uscite dai bordi della scatola negli sport `Gym`, `Swim`, `T_Sprnt` e `W_Polo` come risulta evidenziato nei rispettivi boxplot: la ragione è che in questi casi il numero delle osservazioni è ridotto e sconsiglia di trarre conclusioni statistiche.

Nel terzo grafico (**plot3**) infine i boxplot sono ancora ordinati in base alla mediana dell'emoglobina per sport mentre:
→ in ciascuno sport sono ulteriormente suddivisi per sesso (**fill=sex**);
→ sono lievemente ristretti (**width=.75**);

→ con la funzione **theme()** le etichette sull'asse delle ascisse (**axis.text.x**) sono disposte in verticale.

Questa è la figura risultante.

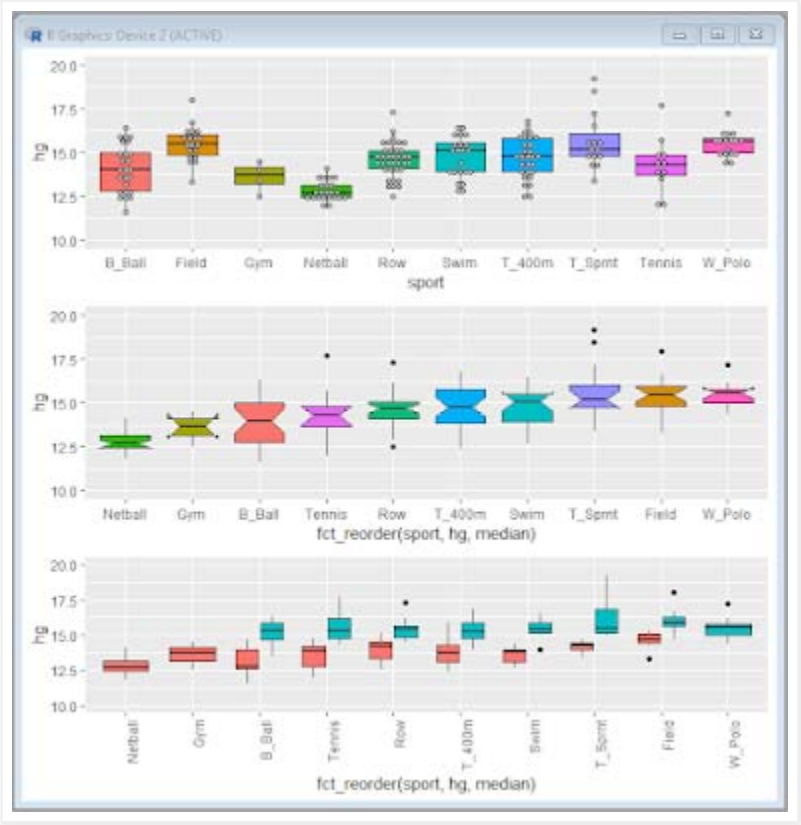

Conclusione: i grafici a scatola con i baffi possono essere realizzati anche impiegando le sole funzioni contenute nella installazione base di **R** [3] con risultati sicuramente adeguati, tuttavia con il pacchetto **ggplot2** è possibile realizzare ulteriori interessanti rappresentazioni.

---

[1] Vedere la documentazione e il manuale di riferimento su:
https://cran.r-project.org/web/packages/ggplot2/index.html

[2] Vedere il post Il set di dati ais nel quale trovate anche come caricare i dati della tabella senza impiegare il pacchetto DAAG.

[3] Vedere il post Grafici a scatola con i baffi (boxplot).