Grafici di dispersione (scatterplot)

I **grafici di dispersione** (*scatter plot* o *scatterplot*) sono lo strumento base per visualizzare su un sistema di coordinate cartesiane le coppie di valori `x,y` di due variabili numeriche nel caso di distribuzioni bivariate.

Prendiamo come esempio i dati ematologici relativi agli eritrociti (o globuli rossi), la cui funzione essenziale come noto è trasportare l'ossigeno dai polmoni a tutti gli altri organi e tessuti, e per i quali valgono in media i seguenti dati (arrotondati per semplicità) :
→ gli eritrociti hanno una concentrazione nel sangue all'incirca di $5 \cdot 10^{12}$/L (ovvero ve ne sono all'incirca cinquemila miliardi in un litro di sangue);
→ un eritrocito ha un volume all'incirca di 90 fL (un femtolitro corrisponde a 10^{-15} litri quindi un globulo rosso ha un volume all'incirca di 0.000 000 000 000 090 litri).

Da questi dati si ricava che la percentuale del volume del sangue occupata dagli eritrociti (detta valore ematòcrito, e uguale alla concentrazione degli eritrociti moltiplicata per il volume di un eritrocito) è il 45% (la restante parte, esclusi i globuli bianchi e le piastrine, che occupano un volume irrilevante, è liquida ed è rappresentata dal plasma). E si ricava anche che deve esistere una proporzionalità diretta tra il numero dei globuli rossi e il volume che occupano. Possiamo quindi dare un senso al prossimo script, che traccia il **grafico di dispersione** di queste due grandezze allo scopo di evidenziarne la relazione.

I dati sono contenuti nella tabella **ais** del pacchetto **DAAG** - accertatevi di avere installato il pacchetto o in alternativa procedete come indicato in [1].

Copiate lo script e incollatelo nella `Console di R` e premete `↵ Invio`:

```
# GRAFICI DI DISPERSIONE (scatterplot)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
str(ais) # struttura di ais
attach(ais) # consente di impiegare direttamente i nomi delle variabili
#
windows() # apre e inizializza una nuova finestra grafica
par(mfrow=c(2,2)) # predispone la suddivisione della finestra in quattro quadranti, uno per grafico
#
plot(rcc, hc, xlab="Eritrociti (10^12/L)", ylab="Ematòcrito (%)", main="Grafico di
dispersione") # grafico di dispersione semplice
#
plot(rcc, hc, pch=2, col="goldenrod", xlab="Eritrociti (10^12/L)", ylab="Ematòcrito (%)",
main="Cambia simbolo e colore") # cambia simbolo e colore
#
plot(rcc, hc, pch=1, col="black", abline(lm(hc~rcc), col="red", lty=1, lwd=1),
xlab="Eritrociti (10^12/L)", ylab="Ematòcrito (%)", main="Retta di regressione") #
grafico con retta di regressione
#
plot(rcc, hc, xlim=c(3,7), ylim=c(30,70), xaxp=c(3, 7, 4), yaxp=c(30, 70, 4), pch=20,
col="black", abline(lm(hc~rcc), col="black", lty=1, lwd=1), xlab="Eritrociti (10^12/L)",
ylab="Ematòcrito (%)", main="Ridimensiona gli assi") # ridimensiona gli assi
#
detach(ais) # termina l'impiego diretto dei nomi delle variabili
#
```

Dopo avere caricato il pacchetto che include il set di dati **ais** e dopo averne mostrato la sua struttura con **str(ais)**, viene impiegata la funzione **attach(ais)** al fine di consente, nelle funzioni successive, di impiegare direttamente i nomi delle variabili incluse nel set di dati.

Per semplificare la presentazione grafica, con **par(mfrow=c(2,2))** la finestra viene suddivisa in quattro quadranti, uno per ciascuno dei grafici che verranno preparati.

Il primo grafico, in alto a sinistra, lascia per gli argomenti della funzione **plot()** i valori di default, specificando solamente quelli essenziali [2]:
→ **rcc** la variabile da riportare sull'asse delle ascisse x;
→ **hc** la variabile da riportare sull'asse delle ordinate y;
→ **xlab=""** l'etichetta da riportare per l'asse delle x;
→ **ylab=""** l'etichetta riportata per l'asse delle y;
→ **main=""** il titolo del grafico che compare in alto.

Nel secondo grafico, in alto a destra, sono aggiunti gli argomenti:
→ **pch=2** che specifica per i dati l'impiego di un simbolo (triangolo) differente da quello di default (che è il cerchio) [3];
→ **col="goldenrod"** che specifica per il simbolo dei dati l'impiego di un colore diverso dal nero [4].

Nel terzo grafico, in basso a sinistra, viene riportata la retta di regressione mediante la funzione **abline()** che impiega come argomenti:
→ l'equazione della retta calcolata con la funzione **lm()** e gli argomenti **hc~rcc** che specificano rispettivamente la variabile in ordinate e la variabile in ascisse;
→ il colore della retta (**col="red"**);
→ il tipo di linea da impiegare (**lty=1**), uno dei sei possibili con i valori da 1 a 6 [5];
→ lo spessore della linea (**lwd=1**) espresso come multiplo dello spessore di default (1 uguale spessore di default, 2 spessore doppio, eccetera).

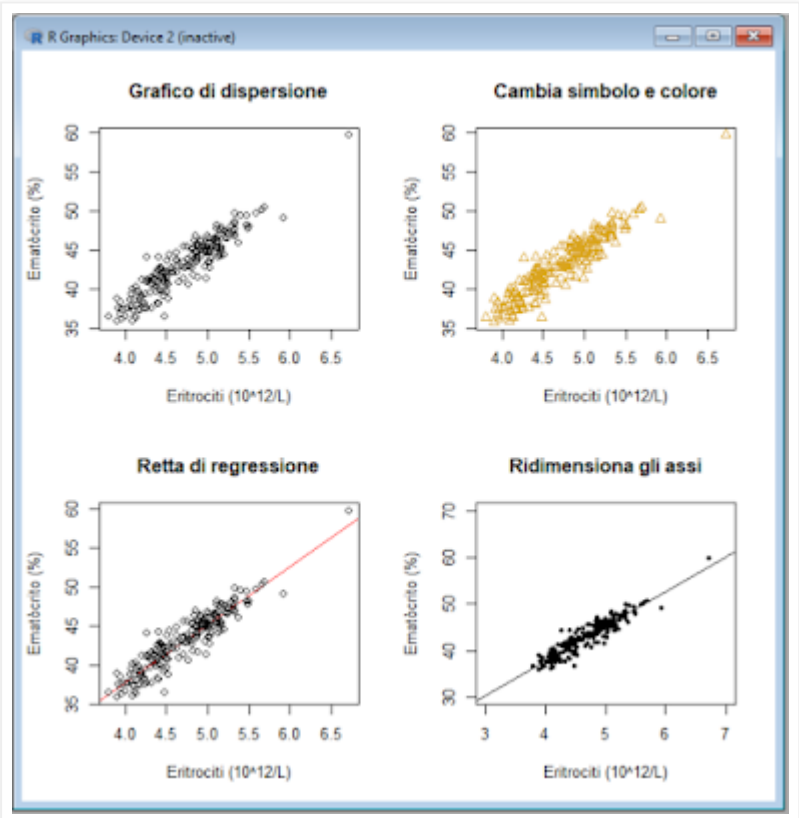

Nel quarto grafico, in basso a destra, compaiono quattro nuovi argomenti, che illustrano come gestire in modo personalizzato le scale degli assi e la loro suddivisione:
→ **xlim = c(3,7)** indica limite inferiore e limite superiore della scala applicata all'asse delle ascisse, trattandosi di valori di concentrazione degli eritrociti espressi in 10^{12}/L questo significa che l'asse

delle ascisse riporterà i valori compresi tra $3 \cdot 10^{12}$/L e $7 \cdot 10^{12}$/L;
→ **ylim = c(30,70)** indica limite inferiore e limite superiore della scala applicata all'asse delle ordinate, che, trattandosi di valori di percentuale, varieranno quindi tra 30% e 70%;
→ **xaxp = c(3, 7, 4)** dice che sull'asse delle ascisse la scala che va da $3 \cdot 10^{12}$/L a $7 \cdot 10^{12}$/L deve essere suddivisa in quattro intervalli, quindi sull'asse delle ascisse compariranno cinque tacche con i valori 3, 4, 50, 6, 7;
→ **yaxp = c(30,70,4)** dice che sull'asse delle ordinate la scala che va da 30% e 70% deve essere suddivisa in quattro intervalli, quindi sull'asse delle ordinate compariranno cinque tacche con i valori 30, 40, 50, 60, 70.

Lo script si chiude con la funzione **detach()** che pone termine all'impiego diretto dei nomi delle variabili. In altre parole la variabile **rcc** ora diventa **ais$rcc**, la variabile **hc** ora diventa **ais$hc** e così via.

I grafici di dispersione riportati qui sopra sono interessanti in quanto sono stati realizzati impiegando esclusivamente le funzioni base di **R**, tuttavia si può fare esteticamente di meglio, come nell'esempio che segue, che per tracciare lo scatterplot impiega le funzioni del pacchetto **ggplot2**.

Copiate lo script e incollatelo nella `Console di R` e premete ↵ `Invio`:

```
# GRAFICO DI DISPERSIONE con ggplot
# colori differenziati in base a un fattore
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
#
windows() # apre e inizializza una nuova finestra grafica
ggplot(ais, aes(x=rcc, y=hc, color=sport)) + geom_point(size=4) + theme_minimal() #
traccia il grafico
#
```

Ed ecco il grafico, nel quale è interessante notare come la funzione **ggplot()** consente di attribuire ai punti un differente colore (**color=**) sulla base dei valori assunti dal fattore **sport**, lo sport praticato: si ottiene in questo modo un grafico di dispersione con evidenziazione dei sottoinsiemi presenti nei dati. Altri esempi che illustrano le varie possibilità di realizzare scatterplot con **ggplot2** sono riportati in un post al quale rimando [6].

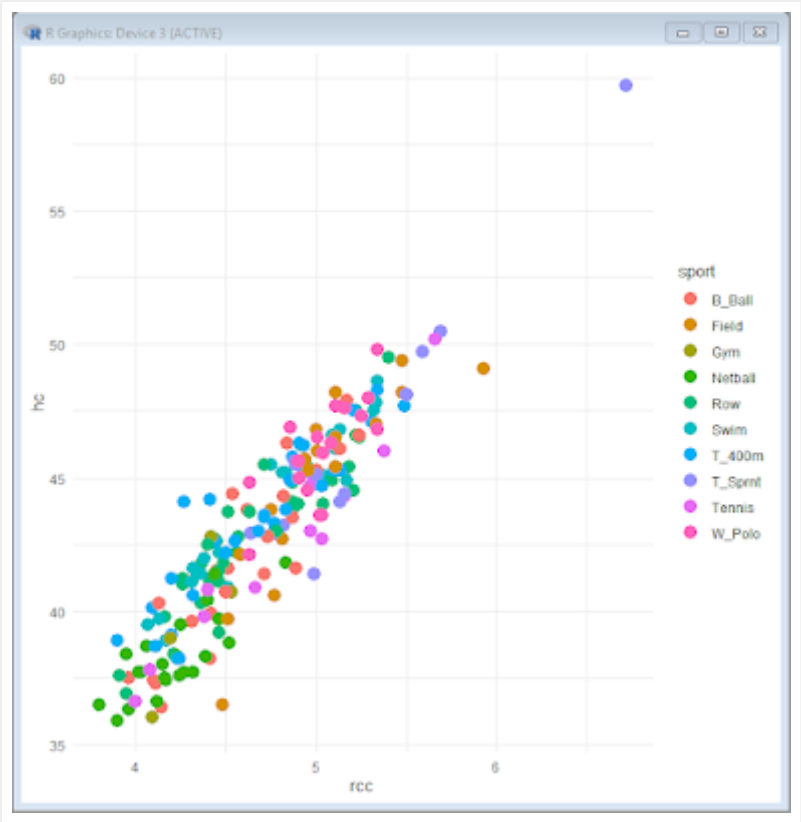

Vediamo ora un **grafico di dispersione multiplo** che aiuta ad illustrare le relazioni tra le variabili riportando tutti i possibili grafici di dispersione singoli che risultano incrociando i dati ematologici contenuti nelle seguenti variabili del set di dati **ais**: **rcc** (eritrociti), **wcc** (leucociti), **hc** (ematòcrito), **hg** (emoglobina) e **ferr** (ferritina).

I grafici sono realizzati mediante i pacchetti aggiuntivi **car** e **gclus**: se non l'avete già fatto, dovete scaricarli e installarli dal **CRAN**.

Copiate e incollate nella `Console di R` lo script e premete `↵ Invio`:

GRAFICI DI DISPERSIONE MULTIPLI
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(car) # carica il pacchetto per la grafica
windows() # apre e inizializza una nuova finestra grafica
#
grafici di dispersione con istogrammi delle variabili
#
scatterplotMatrix(~rcc+wcc+hc+hg+ferr, col="black", pch=20, regLine = list(method=lm, lty=1, lwd=2, col="chartreuse3"), smooth=FALSE, diagonal=list(method ="histogram", breaks="FD"), main="Matrice di dispersione con rette di regressione", data=ais) # mostra il grafico
#

L'argomento **~rcc+wcc+hc+hg+ferr** definisce le variabili da rappresentare, e può essere facilmente riscritto aggiungendo e togliendo variabili per cambiare la rappresentazione a piacere.

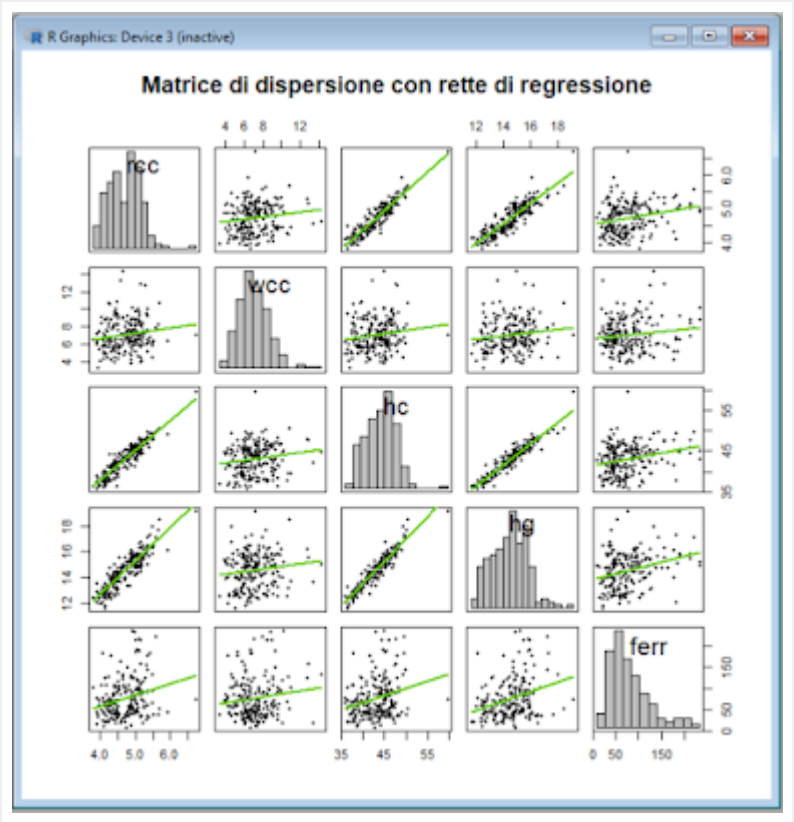

Per la retta di regressione sono impiegati una linea continua (**lty=1**), uno spessore doppio (**lwd=2**) e un colore (**col="chartreuse3"**) diverso dal nero, mentre l'argomento **smooth=FALSE** fa si che non venga aggiunta ai grafici la rappresentazione della funzione non lineare prevista di default nel pacchetto **car**.

Infine l'argomento **diagonal=list()** indica la rappresentazione della variabile riportata nella diagonale, che qui è l'istogramma (**method ="histogram"**) con il numero di classi (**breaks="FD"**) calcolato mediante la regola di Freedman-Diaconis. L'istogramma può essere sostituito con altri tipi di rappresentazione, l'elenco delle espressioni che è possibile impiegare in alternativa per questo argomento (provatele) è:
→ **diagonal=list(method="density", bw="nrd0", adjust=1, kernel="gaussian", na.rm=TRUE)**
→ **diagonal=list(method="boxplot")**
→ **diagonal=list(method="qqplot")**
→ **diagonal=list(method="oned")**

Infine copiate e incollate nella `Console di R` lo script e premete `↵ Invio`:

GRAFICI DI DISPERSIONE MULTIPLI ordinati in base al valore di r
#
library(DAAG) # carica il pacchetto incluso il set di dati ais
library(gclus) # carica il pacchetto per la grafica
windows() # apre e inizializza una nuova finestra grafica
mydata <- ais[c(1,2,3,4,5)] # tabella con i dati delle variabili delle colonne 1,2,3,4,5
mydata.r <- abs(cor(mydata)) # calcola la correlazione
mydata.col <- dmat.color(mydata.r) # applica i colori
mydata.o <- order.single(mydata.r) # ordina le variabili, le meglio correlate più vicine alla diagonale
cpairs(mydata, mydata.o, panel.colors=mydata.col, gap=.5, main="Variabili meglio correlate vicine alla diagonale") # mostra il grafico
#

In quest'ultimo caso viene realizzato un grafico di dispersione multiplo che incrocia ancora i dati ematologici degli atleti contenuti nelle cinque variabili **rcc** (eritrociti), **wcc** (leucociti), **hc** (ematòcrito), **hg** (emoglobina) e **ferr** (ferritina) ma con due novità.

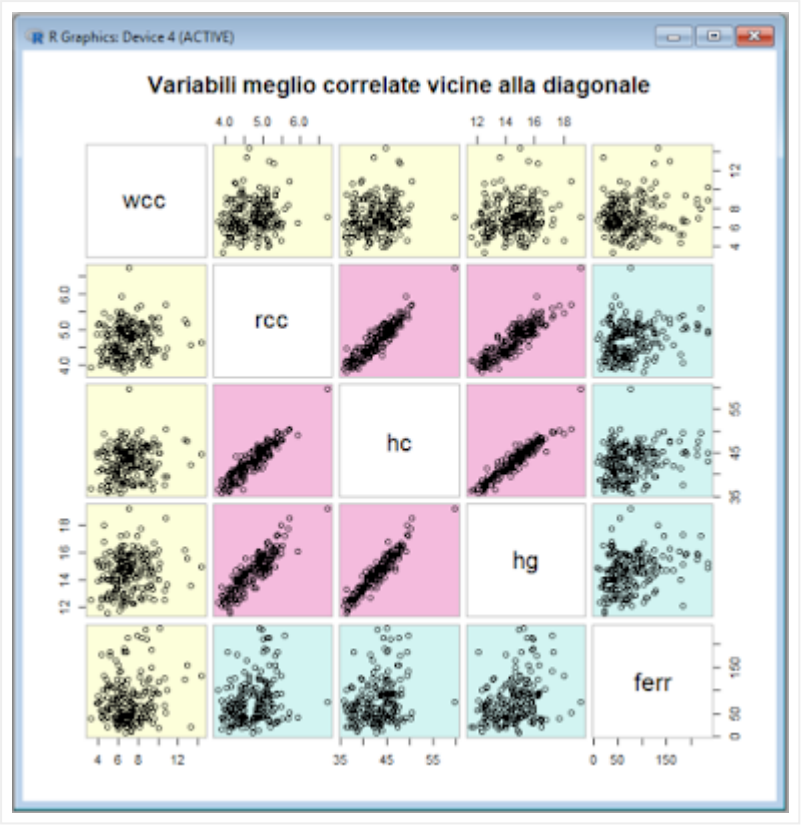

La prima è che le variabili ora sono individuate non mediante il loro nome bensì indicando, con l'espressione **ais[c(1,2,3,4,5)]**, il set di dati che le contiene e il numero della colonna corrispondente a ciascuna variabile

La seconda novità è che impiegando la funzione **cpairs()** [7] abbiamo un grafico di dispersione multiplo ordinato in base al valore del coefficiente di correlazione r di Pearson, in modo che le variabili meglio correlate siano le più vicine alla diagonale ed evidenziate in colore, aumentando così la chiarezza della rappresentazione grafica.

Potete riutilizzare facilmente lo script sostituendo all'oggetto **ais** l'oggetto contenente i vostri dati, opportunamente strutturati, e modificando conseguentemente i nomi della variabili. Per una guida rapida all'importazione dei dati potete consultare i post:
→ importazione dei dati da un file .csv
→ importazione dei dati da un file .xls o .xlsx
→ gestione dei dati mancanti

---

[1] Vedere il post Il set di dati ais nel quale trovate anche come caricare i dati della tabella senza impiegare il pacchetto **DAAG**.

[2] Per la documentazione sugli argomenti della funzione **plot()** digitare **help(plot)** nella `Console di R`, e in aggiunta consultare la documentazione sugli argomenti della funzione **par()** con **help(par)**.

[3] Per i diversi simboli che è possibile impiegare per tracciare i punti vedere il post I simboli dei punti di R.

[4] Per i colori che è possibile impiegare vedere il post La tabella dei colori di R.

[5] Per le linee che è possibile impiegare vedere il post Gli stili delle linee di R.

[6] Vedere il post Grafici di dispersione (scatterplot) con ggplot.

[7] Digitate **help(cpairs)** nella `Console di R` per la documentazione della funzione **cpairs()** ovvero consultate il manuale di riferimento del pacchetto **gclus** su: *Available CRAN Packages By Name*.
https://cran.r-project.org/web/packages/available_packages_by_name.html