Grafici di dispersione (scatterplot) con ggplot

I **grafici di dispersione** (*scatter plot* o *scatterplot*) forniscono un ottimo esempio delle potenzialità delle funzioni del pacchetto **ggplot2** [1] nella rappresentazione grafica dei dati. Funzioni che possono risultare ostiche a chi le affronta per la prima volta, ma che consentono risultati che non si riescono a ottenere impiegando esclusivamente le funzioni base di **R** [2].

Oltre al pacchetto **ggplot2** bisogna avere installato – o bisogna scaricare anche – il pacchetto **DAAG** [3] che contiene i dati impiegati nell'esempio e il pacchetto **gridExtra** che nel nostro caso è necessario per combinare più grafici in una sola figura.

Copiate e incollate nella `Console di R` questo script e premete ↵ `Invio`.

```
# SCATTERPLOT con ggplot
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
library(gridExtra) # carica il pacchetto per combinare i grafici in una sola figura
#
# scatterplot
plot1 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point()
#
# con regressione loess
plot2 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point() + geom_smooth()
#
# con regressione lineare
plot3 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point() + geom_smooth(method="lm")
#
# con la densità di distribuzione
plot4 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point(aes(color="red")) +
geom_density_2d() + theme_classic() + labs(title="Densità di distribuzione \n tutti i
casi", x="Eritrociti in 10^6/µL", y="Emoglobina in g/dL") +
theme(plot.title=element_text(hjust=0.5), legend.position="none")
#
# combina i grafici in una sola figura
grid.arrange(plot1, plot2, plot3, plot4, nrow=2, ncol=2)
#
```

Lo script è semplice: dopo avere caricato i pacchetti necessari, sono generati quattro grafici che sono salvati separatamente per essere poi, al termine, combinati in una sola figura.

Per realizzare il primo grafico (**plot1**) viene impiegata la funzione **ggplot()** che inizializza l'oggetto al quale sono collegate con il segno più [**+**] le successive funzioni, che sviluppano la grafica e che prevede:
→ come primo argomento il nome della tabella che contiene i dati (**ais**) [3];
→ come secondo argomento la funzione **aes()** che specifica la variabile da riportare in ascisse (**rcc**) e la variabile da riportare in ordinate (**hg**), che sono rispettivamente la concentrazione degli eritrociti nel sangue espressa in milioni per microlitro di sangue (`10^6/µL`) e la concentrazione di emoglobina espressa in grammi per decilitro di sangue (`g/dL`).

Alla funzione **ggplot()** viene quindi collegata con il segno più [**+**] la funzione **geom_point()** che realizza il *grafico xy* lasciando per tutti gli argomenti i valori previsti di default.

Da notare subito che questa è la struttura base che rimane identica in tutti e quattro i grafici realizzati, che si differenziano tra loro per le componenti grafiche via via aggiunte.

Il secondo grafico (**plot2**) quindi riprende tal quale la precedente struttura base e aggiunge semplicemente tramite la funzione **geom_smooth()**, la *regressione loess* prevista di default, con i suoi limiti di confidenza (la regressione loess è una regressione che collega tra loro una serie di regressioni polinomiali, quelle che localmente meglio si adattano ai dati).

Nel terzo grafico (**plot3**) impiegando l'argomento **method** la regressione loess è sostituita con la usuale retta di regressione (**"lm"**), riportando anche in questo caso i limiti i confidenza. Se non li volete rappresentare correggete la riga di codice sostituendola completamente con la seguente o semplicemente aggiungendo quanto qui riportato in colore

```
# con regressione lineare
plot3 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point() +
geom_smooth(method="lm", se=FALSE)
#
```

Il quarto grafico (**plot4**) riprende la struttura base aggiungendo:
→ con **aes(color="red")** un colore ai punti che rappresentano i dati;
→ con la funzione **geom_density_2d()** la rappresentazione sul piano dei livelli di densità nella distribuzione dei dati;
→ con la funzione **theme_classic()** il cambiamento di stile che risulta evidente nell'ultimo grafico;
→ con la funzione **labs()** il titolo e le etichette degli assi, Da notare il simbolo **\n** che all'interno di una stringa di testo determina il ritorno a capo;
→ con la funzione **theme()** il codice (abbastanza arzigogolato) che determina la centratura del titolo e il valore **"none"** per l'argomento **legend.position** che determina la posizione della legenda, che pertanto non viene riportata.

Infine con la funzione **grid.arrange()** i quattro grafici sono combinati in un'unica figura.

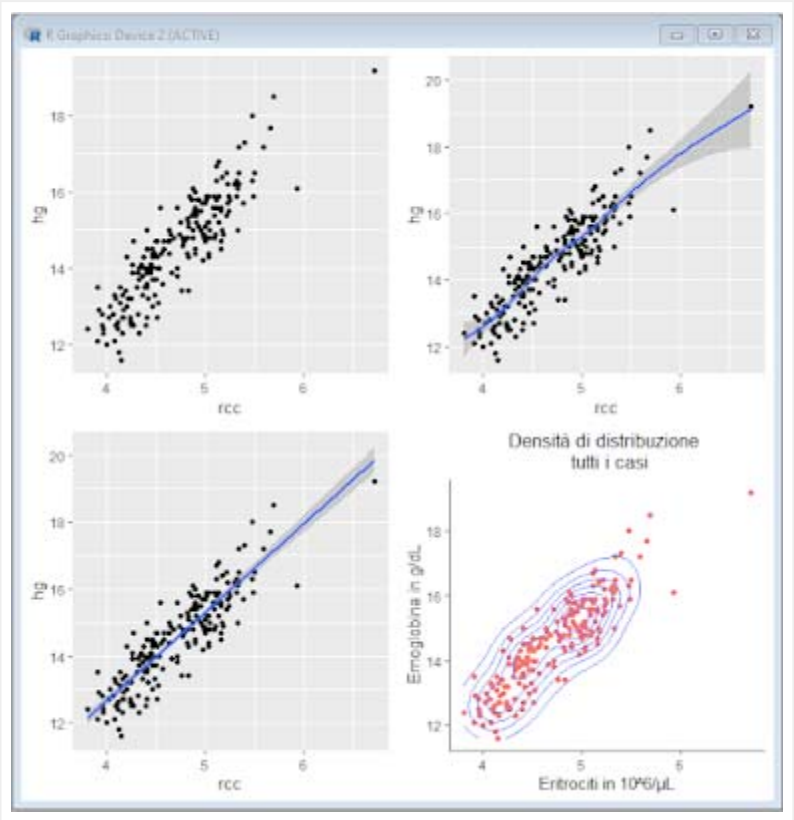

Ora copiate e incollate nella `Console di R` questo secondo script che ha come obiettivo evidenziare la semplicità con la quale possiamo effettuare in un grafico rappresentazioni separate in base a un fattore che nel nostro caso è la variabile sesso (**sex**), in quanto il set di dati **ais** contiene dati ematologici e dati biometrici, rilevati in atleti australiani sia di sesso femminile sia di sesso maschile.

```
# SCATTERPLOT con ggplot
# colori differenziati in base a un fattore
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
library(gridExtra) # carica il pacchetto per combinare i grafici in una sola figura
#
# scatterplot per sesso
plot1 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point(aes(color=sex))
#
# con simboli dei punti differenziati
plot2 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point(aes(color=sex, shape=sex)) +
theme(legend.position="none")
#
# con rette di regressione e limiti di confidenza
plot3 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point(aes(color=sex, shape=sex)) +
theme(legend.position="none") + geom_smooth(aes(group=sex, color=sex),
method="lm", se=TRUE)
#
# con rette di regressione estese
plot4 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point(aes(color=sex, shape=sex)) +
theme(legend.position="none") + geom_smooth(aes(group=sex, color=sex),
method="lm", se=FALSE, fullrange=TRUE)
#
# combina i grafici in una sola figura
grid.arrange(plot1, plot2, plot3, plot4, nrow=2, ncol=2)
#
```

Per realizzare il primo grafico (**plot1**) viene impiegata la struttura base già vista nello script precedente, ma con la semplice aggiunta a **geom.point** della funzione **aes()** che con l'argomento **color** posto uguale a **sex** riporta i dati con un colore differenziato in base al sesso.

Il secondo grafico (**plot2**) riprende tal quale il codice precedente ma:
→ alla funzione **geom_point()** aggiunge l'argomento **shape=sex** che automaticamente riporta un simbolo differente in base al sesso;
→ con la funzione **theme()** esclude dal grafico la legenda.

Il terzo grafico (**plot3**) è identico al secondo ma con la funzione **geom_smooth()** aggiunge la retta di regressione ordinaria (**method="lm"**) con i limiti di confidenza (**se=TRUE**) separatamente (**group=sex**) e con un colore diverso (**color=sex**) per ciascun sesso.

Il quarto grafico (**plot4**) riprende esattamente il codice del terzo ma con **se=FALSE** esclude la rappresentazione dei limiti di confidenza e con **fullrange=TRUE** riporta la retta di regressione a tutto campo e al di la dei limiti dei dati osservati (per inciso si ricorda che, a meno di casi particolari e adeguatamente giustificati, l'estrapolazione non andrebbe mai fatta, ma viene qui riportata per completezza).

Infine con la funzione **grid.arrange()** i quattro grafici sono di nuovo combinati, per semplicità, in un'unica figura.

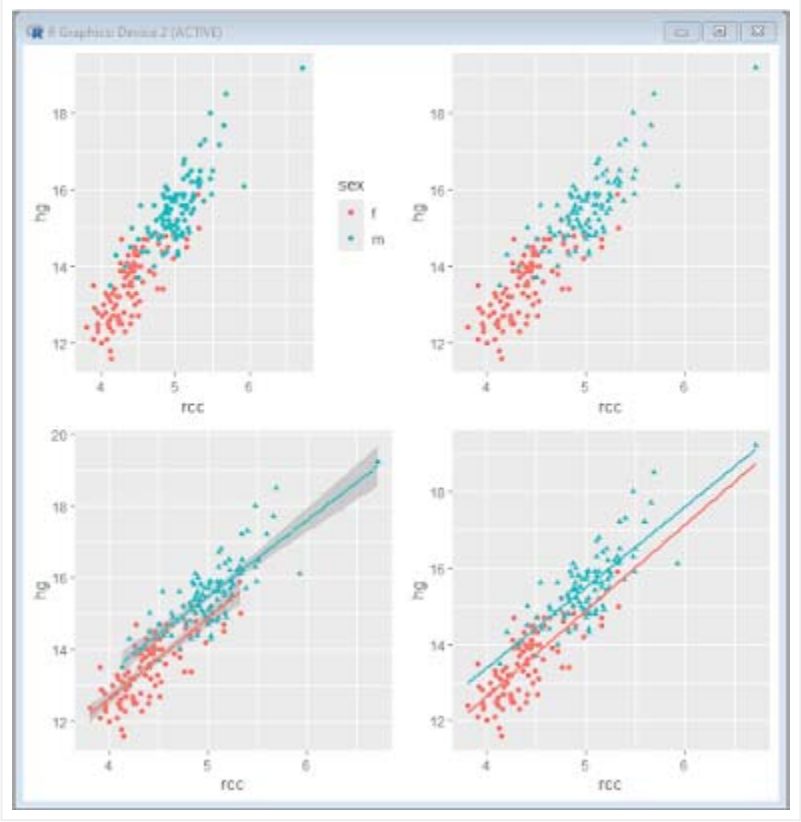

Ora copiate e incollate nella `Console di R` questo script e premete ↵ `Invio`.

```
# SCATTERPLOT con ggplot
# dati con densità delle distribuzioni
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
library(gridExtra) # carica il pacchetto per combinare i grafici in una sola figura
#
# scatterplot con ellissi
plot1 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point(aes(color=sex, shape=sex)) +
theme(legend.position="none") + stat_ellipse(aes(color=sex))
#
# con densità di distribuzione della y
plot2 <- ggplot(ais, aes(y=hg, fill=sex)) + geom_density(alpha=0.5) +
theme(legend.position="none")
#
# con densità di distribuzione della x
plot3 <- ggplot(ais, aes(x=rcc, fill=sex)) + geom_density(alpha=0.5) +
theme(legend.position="none")
#
# con livelli di densità separati per sesso
plot4 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point(aes(color=sex, shape=sex)) +
theme(legend.position="none") + geom_density_2d(aes(color=sex))
#
# combina i grafici in una sola figura
grid.arrange(plot1, plot2, plot3, plot4, nrow=2, ncol=2)
#
```

Il primo grafico (**plot1**) riprende le funzioni già note, ma aggiunge, con la funzione **stat_ellipse()**, le ellissi che riportano i limiti di confidenza al 95% delle distribuzioni dei dati, separate per ciascun sesso e ulteriormente analizzate con il secondo e il terzo grafico.

Il secondo grafico (**plot2**) riporta in ordinate per la variabile emoglobina (**y=hg**) e separatamente per ciascun sesso (**fill=sex**), con la funzione **geom_density()**, il kernel density plot, con un colore trasparente al 50% (**alpha=0.5**) per consentirne la sovrapposizione. Da notare due aspetti non banali gestiti automaticamente dalle funzioni qui impiegate: gli assi sono ruotati nella posizione corretta e per l'asse delle ordinate la scala nella quale sono espressi i valori di concentrazione dell'emoglobina (**hg**) è allineata con quella del primo grafico.

Il terzo grafico (**plot3**) riporta in modo analogo ma in ascisse il kernel density plot per sesso della variabile concentrazione degli eritrociti (**x=rcc**). Da notare che anche in questo caso gli assi sono automaticamente ruotati nella posizione corretta e per l'asse delle ascisse la scala nella quale sono espressi i valori di concentrazione degli eritrociti (**rcc**) è automaticamente allineata con quella del primo grafico.

In definitiva i primi tre grafici formano un tutt'uno organico – con le variabili rappresentate contemporaneamente sia singolarmente in forma di grafico xy sia in forma di grafici che ne riportano in continuo la densità (kernel density plot) – che fornisce un'analisi molto interessante dei dati, mostrando come la distribuzione dei valori di concentrazione dell'emoglobina nel sangue differisce nei due sessi.

Il quarto grafico (**plot4**) riprende esattamente il primo aggiungendo questa volta al posto delle ellissi con la funzione **geom_density_2d()** la rappresentazione sul piano dei livelli di densità nella distribuzione dei dati.

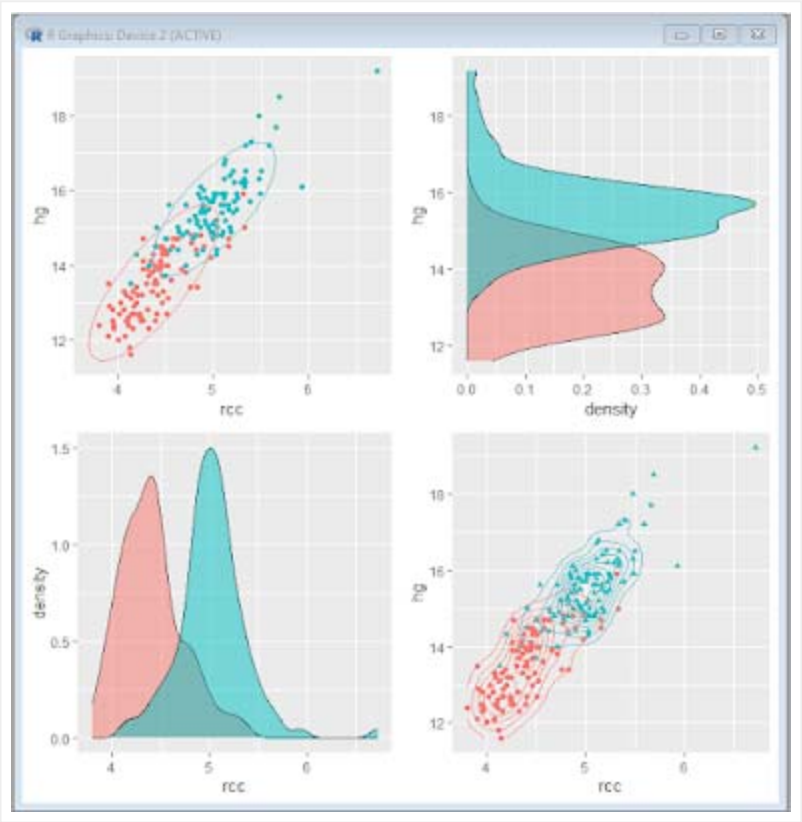

Se vedendo il grafico notate che preferireste (io lo preferisco di gran lunga) che i due kernel density plot fossero riferiti al grafico in basso a destra, niente di più facile, copiate e incollate nella `Console di R` questo script e premete ↵ `Invio`.

```
# SCATTERPLOT con ggplot
# dati con densità delle distribuzioni
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
library(gridExtra) # carica il pacchetto per combinare i grafici in una sola figura
#
# scatterplot con ellissi
plot1 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point(aes(color=sex, shape=sex)) +
theme(legend.position="none") + stat_ellipse(aes(color=sex))
#
# con densità di distribuzione della y
plot2 <- ggplot(ais, aes(y=hg, fill=sex)) + geom_density(alpha=0.5) +
theme(legend.position="none") + scale_x_reverse()
#
# con densità di distribuzione della x
plot3 <- ggplot(ais, aes(x=rcc, fill=sex)) + geom_density(alpha=0.5) +
theme(legend.position="none")
#
# con livelli di densità separati per sesso
plot4 <- ggplot(ais, aes(x=rcc, y=hg)) + geom_point(aes(color=sex, shape=sex)) +
theme(legend.position="none") + geom_density_2d(aes(color=sex))
#
# combina i grafici in una sola figura
grid.arrange(plot1, plot3, plot2, plot4, nrow=2, ncol=2)
#
```

Come si vede il codice è identico al precedente, a parte il fatto che dovete:
→ scambiare tra di loro i grafici (**plot3, plot2,**) quando li combinate in un'unica figura (ultima riga di codice), portando quindi il kernel density plot degli eritrociti (`rcc`) in alto a destra e quello dell'emoglobina (`hg`) in basso a sinistra;
→ aggiungere con (**+**) al **plot2** la funzione **scale_x_reverse()** per invertire la scala dell'asse delle ascisse e quindi la rappresentazione del kernel density plot.

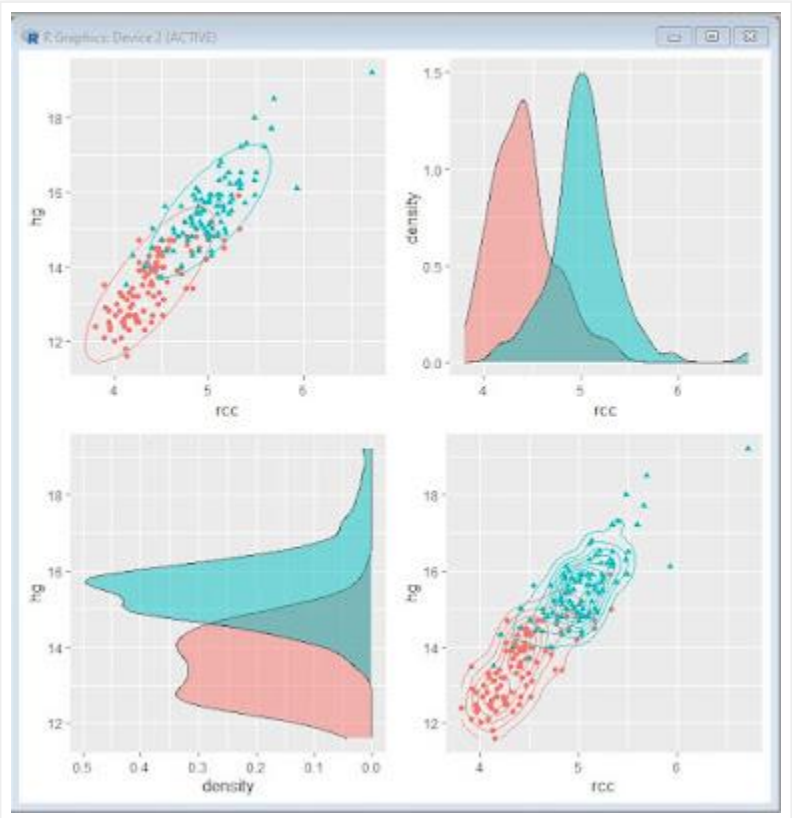

Ricordate, perché prima o poi vi tornerà utile, che qualora fosse necessario potete anche invertire la scala dell'asse delle ordinale con **scale_y_reverse()** e scambiare di posizione gli assi con **coord_flip()**.

Concludiamo con questo script, copiatelo e incollatelo nella `Console di R` e premete ↵ `Invio`:

```
# GRAFICO DI DISPERSIONE con ggplot
# colori differenziati in base a un fattore
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
#
windows() # apre e inizializza una nuova finestra grafica
ggplot(ais, aes(x=rcc, y=hg, color=sport)) + geom_point(size=3) + theme_minimal() #
traccia il grafico
#
```

Ed ecco il grafico

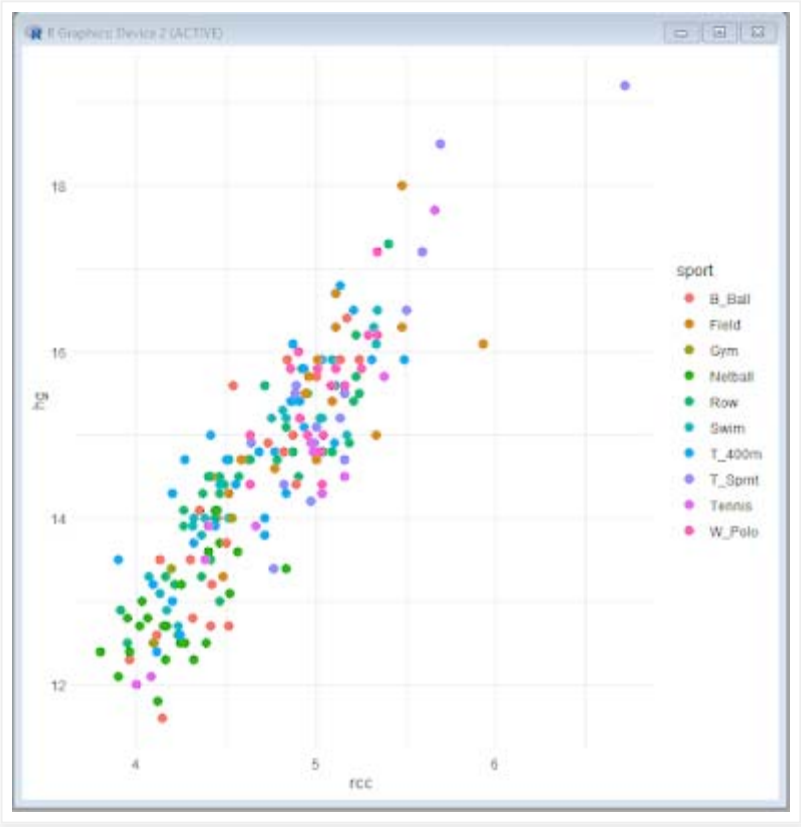

che ci consente di mostrare come la funzione **ggplot()** sia in grado di coniugare semplicità e potenza nella rappresentazione dei grafici di dispersione (scatterplot).

Sono infatti sufficienti come argomenti della funzione solamente:
→ la tabella che include i dati (**ais**);
→ la x (**rcc**) e la y (**hg**) da rappresentare;
→ l'indicazione della variabile "fattore" (**sport**) che contiene i valori (lo sport praticato) sulla base dei quali attribuire ai punti un differente colore (**color=**);
mentre sono facoltativi e aggiunti solamente per completezza la dimensione dei punti (**size=3**) e la funzione **theme_minimal()** che toglie il colore grigio di sfondo.

Conclusione: questa breve presentazione ha voluto evidenziare come le funzioni incluse nel pacchetto **ggplot2** possono sia essere impiegate in modo agevole, sia fornire un importante

aiuto nella introspezione dei dati e nella comunicazione dell'informazione in essi contenuta [4].

---

[1] Vedere la documentazione e il manuale di riferimento su:
https://cran.r-project.org/web/packages/ggplot2/index.html

[2] Vedere il post Grafici di dispersione (scatterplot).

[3] Vedere il post Il set di dati ais nel quale trovate anche come caricare i dati senza impiegare il pacchetto **DAAG**.

[4] Ovviamente potete procedere con ulteriori approfondimenti impiegando la documentazione del pacchetto [1], ma potete anche valutare al bisogno l'opportunità di ricorrere a qualcuno dei corsi sull'argomento disponibili sul web, cito per tutti un esempio, "*Introduction to Data Visualization with ggplot2*":
https://www.datacamp.com/courses/introduction-to-data-visualization-with-ggplot2