Grafici di dispersione (scatterplot) per fattore con ggplot

La statistica è l'arte sottile che consente di ricavare informazione dai dati. Vediamo come ciò sia possibile impiegando anche semplici **grafici di dispersione** ma in questo caso **separati per fattore**.

Il punto di partenza è un grafico xy della distribuzione dei valori di concentrazione nel sangue dei globuli rossi (in ascisse) e dell'emoglobina (in ordinate) misurati in 202 atleti australiani di entrambi i sessi che praticano dieci differenti sport e contenuti nel set di dati **ais**.

```
# SCATTERPLOT semplice con ggplot
#
library (DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
#
# scatterplot semplice
ggplot(ais, aes(x=rcc, y=hg, color=sport)) + geom_point()
#
```

Le prime due righe servono a caricare i due pacchetti necessari, che devono essere preventivamente scaricati dal **CRAN**, e il primo dei quali contiene il set di dati [1].

Per realizzare il grafico viene impiegata la funzione **ggplot()** che prevede come argomenti:
→ il nome della tabella che contiene i dati (**ais**);
→ la funzione **aes()** che specifica la variabile da riportare in ascisse (**rcc**) e la variabile da riportare in ordinate (**hg**), che sono rispettivamente la concentrazione degli eritrociti (o globuli rossi) nel sangue espressa in milioni per microlitro di sangue (10^6/μL) e la concentrazione di emoglobina espressa in grammi per decilitro di sangue (g/dL);
→ il colore dei punti (**color**) separato per ciascuno degli sport praticati e codificati nella variabile **sport**.

Alla funzione **ggplot()** viene quindi collegata con il segno più [**+**] la funzione **geom_point()** che realizza il grafico impiegando i valori previsti di default e individuando gli sport praticati con un colore.

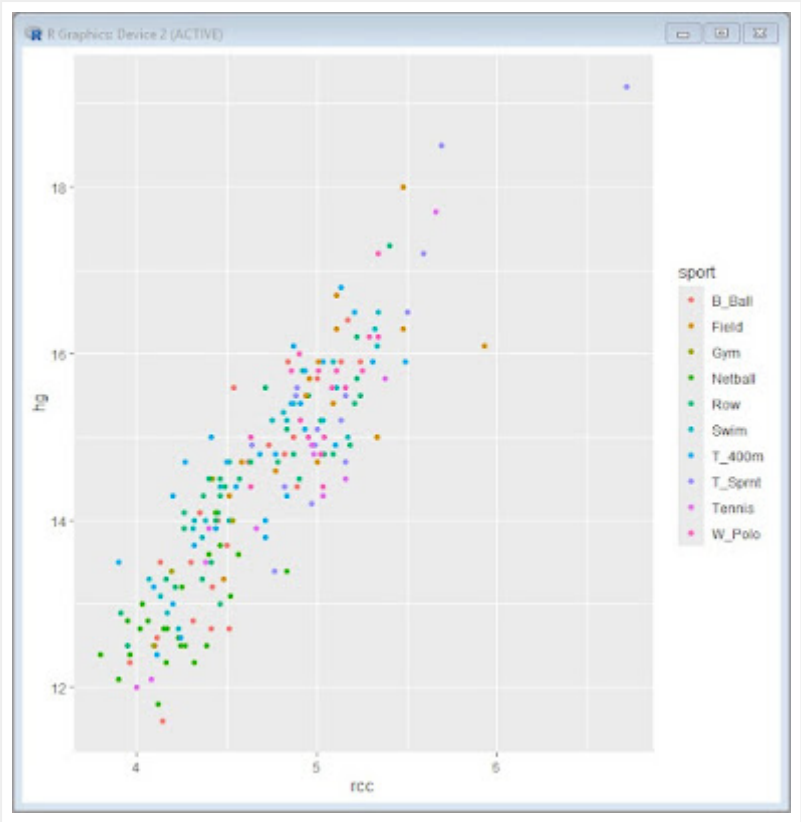

Visto il grado di sovrapposizione dei dati, vogliamo provare a separarli generando dieci scatterplot, uno per ciascuno degli sport. Ecco lo script necessario e i grafici risultanti.

```
# SCATTERPLOT separati per fattore
#
library (DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
#
# scatterplot separati per il fattore sport
ggplot(ais, aes(x=rcc, y=hg, color=sport)) + geom_point() + facet_wrap(~sport)
#
```

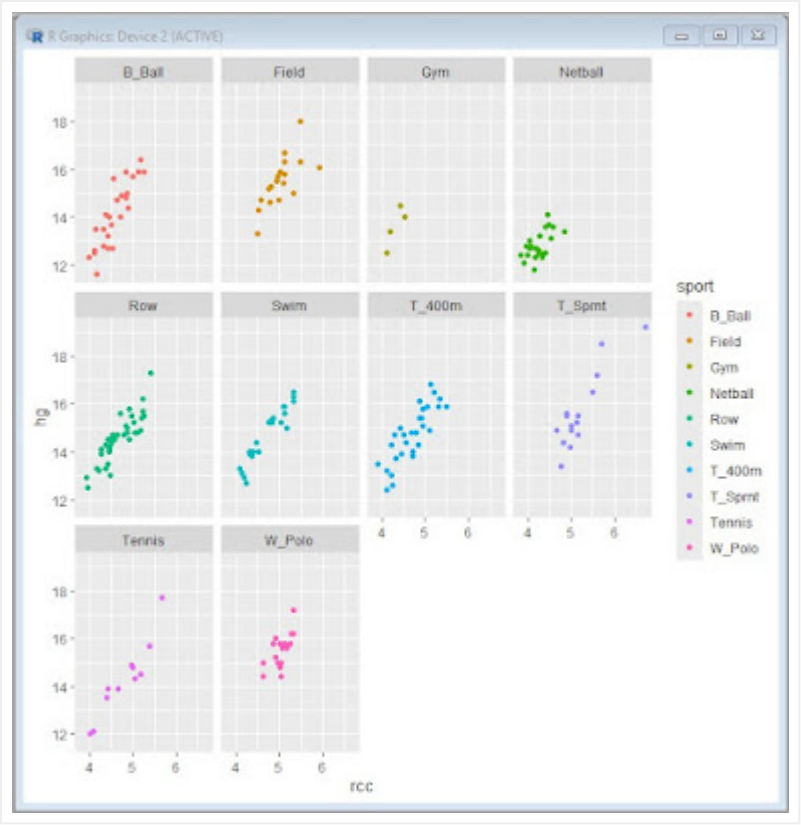

Quindi per scomporre i dati nei dieci sottoinsiemi rappresentativi di ciascuno sport è stato sufficiente, al codice necessario per realizzare il grafico di dispersione che riporta tutti i dati, aggiungere (**+**) la funzione **facet_wrap()** specificando che i dati devono essere suddivisi per sport (**~sport**).

Possiamo anche migliorare il grafico come segue.

```
# SCATTERPLOT riorganizzati per righe
#
library (DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
#
# scatterplot riorganizzati per righe
ggplot(ais, aes(x=rcc, y=hg, color=sport)) + geom_point(show.legend=FALSE) +
facet_wrap(~sport, nrow=2)
#
```

In questo caso:
→ visto che la rappresentazione fornita contiene già le etichette che individuano i dati, è stata eliminata la legenda (**show.legend=FALSE**);
→ i grafici sono stati riorganizzati su due righe con **nrow=2**, con questo risultato.

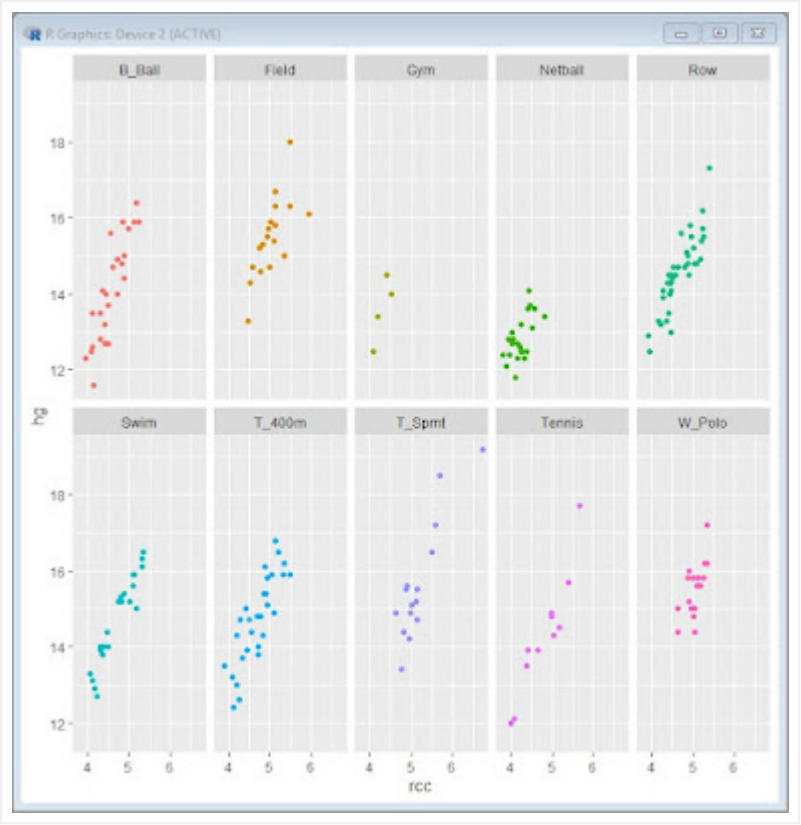

Dei nostri dati abbiamo quindi realizzato una *grafica sintetica* (primo script) e poi abbiamo visto come realizzare una *grafica analitica*: ma che dire se potessimo visualizzarle contemporaneamente entrambe? Ecco come è possibile farlo.

```
# SCATTERPLOT sovrapposti ai dati globali
#
library (DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
#
# scatterplot separati sovrapposti alla distribuzione globale dei dati
ggplot(ais, aes(x=rcc, y=hg, color=sport)) + geom_point(data=transform(ais,
sport=NULL), colour="grey82") + geom_point(show.legend = FALSE) +
facet_wrap(~sport, nrow=2, strip.position="bottom")
#
```

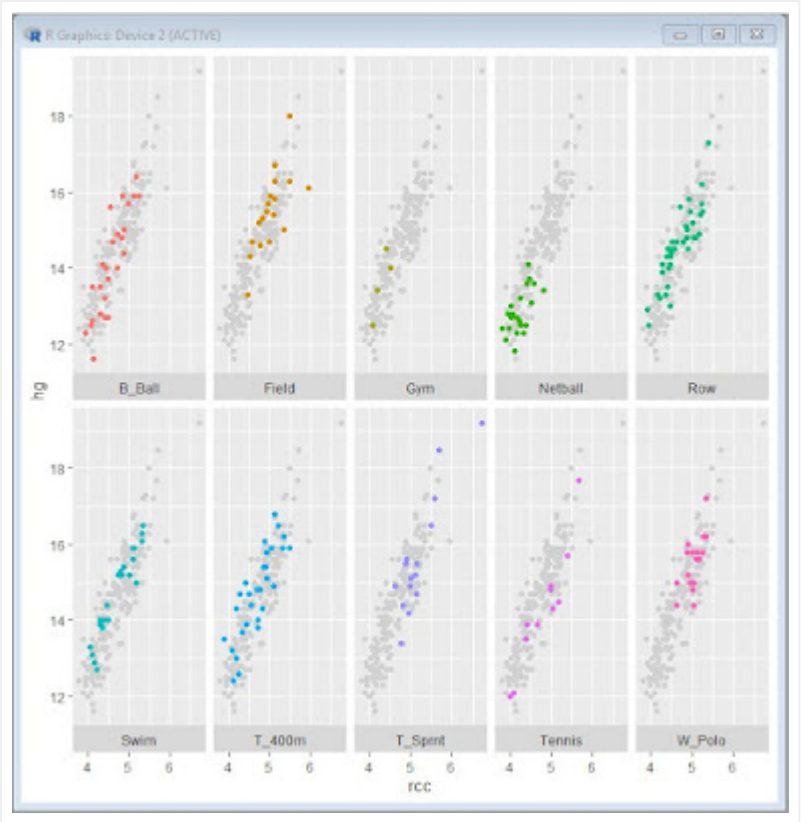

Nota: i grafici mettono in rilievo l'informazione che la distribuzione dei valori non è omogenea in tutti gli sport – ad esempio gli atleti che praticano lo sport *Netball* hanno concentrazioni di eritrociti ed emoglobina relativamente basse e all'estremo opposto di quelle relativamente alte che si riscontrano negli atleti che praticano pallanuoto (*W_Polo*).

In questo caso viene aggiunta una nuova funzione **geom_point()** che elimina dai dati la variabile sport (**sport=NULL**) mediante la funzione **transform()** per riportarli tutti nel grafico – in colore grigio (**colour="grey82"**) – prima che ad essi con le successive funzioni **geom_point()** e **facet_wrap()** siano sovrapposti separatamente i dati dei singoli sport.

Da notare che la funzione **facet_wrap()** tra le altre cose:
→ consente con l'argomento **strip.position** di personalizzare la posizione delle etichette, con il valore predefinito "**top**", che può essere cambiato in "**bottom**" (come in questo caso), "**left**" o "**right**";
→ consente con l'argomento **scales** di specificare il tipo di scale impiegate, con il valore predefinito "**fixed**" che assume come in questo caso scale degli assi x e y uguali in tutti i grafici, e con i valori "**free**", "**free_x**" o "**free_y**" da impiegare qualora siano previste scale differenti degli assi.

Per completare l'analisi grafica dei dati la eseguiamo anche per il sesso degli atleti sostituendo **sport** con **sex**, il nome della variabile fattore che contiene l'indicazione del sesso dell'atleta [1].

```
# SCATTERPLOT sovrapposti ai dati globali
#
library (DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto per la grafica
#
# scatterplot separati sovrapposti alla distribuzione globale dei dati
ggplot(ais, aes(x=rcc, y=hg, color=sex)) + geom_point(data=transform(ais, sex=NULL),
colour="grey82") + geom_point(show.legend=FALSE) + facet_wrap(~sex, nrow=2,
strip.position="bottom")
#
```

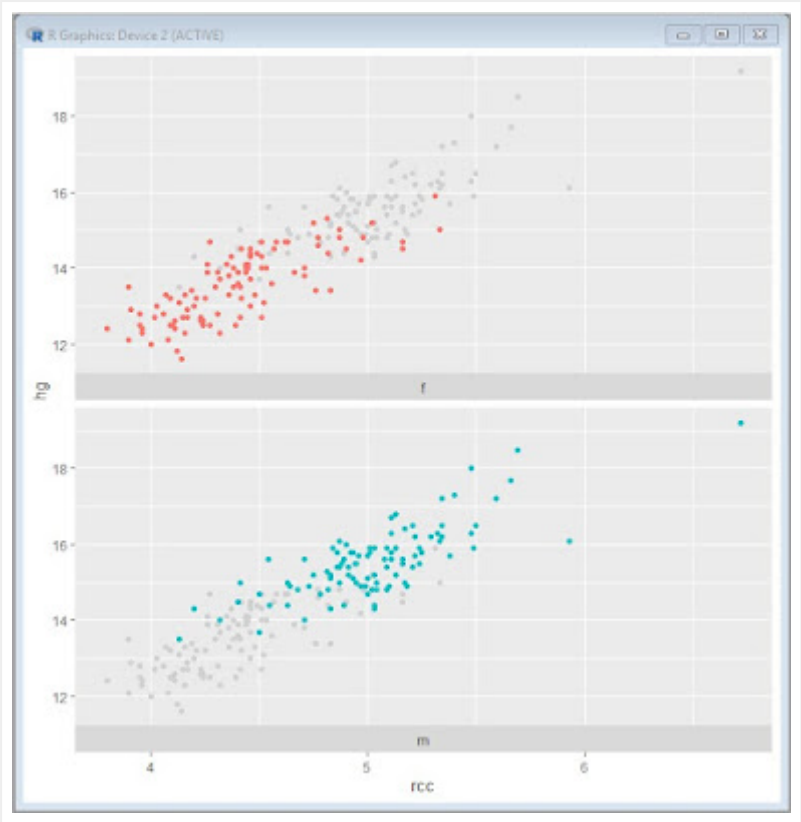

In questo caso il grafico mette in evidenza che la distribuzione del valori non è omogenea nei due sessi, un fatto che rispecchia i differenti "valori normali" dei globuli rossi e dell'emoglobina nelle donne e negli uomini (valori che sono fisiologicamente mediamente inferiori nelle prime rispetto ai secondi).

Conclusione: opportunamente impiegati i grafici xy consentono di ricavare dai dati informazioni che vanno al di la della semplice relazione tra due variabili.

---

[1] Vedere il post Il set di dati ais nel quale trovate anche come caricare i dati senza impiegare il pacchetto **DAAG**.