Grafici a linee (line chart) con ggplot

Un **grafico a linee** (*line chart*) può essere realizzato, oltre che impiegando le funzioni base di **R** [1], anche con le funzioni del pacchetto **ggplot2** come vediamo ora.

I dati qui utilizzati come esempio sono contenuti nel dataset "`Indometh`" incluso nella *installazione base* di **R**: per vedere gli altri dataset disponibili con questa (ma molti altri sono disponibili nei vari pacchetti aggiuntivi) e che possono essere utili per esercitarsi, digitare

data()

nella `Console di R` e premere ↵ `Invio`.

Digitando il nome

Indometh

del dataset che ci interessa vediamo che contiene la concentrazione (`conc`) nel siero (espressa in µg/mL cioè in microgrammi per millilitro) del farmaco *indometacina* (un farmaco antinfiammatorio), misurata secondo la stessa precisa sequenza di ore (`time`) in sei soggetti (`Subject`) identificati con i numeri da `1` a `6` :

```
   Subject time conc
1        1 0.25 1.50
2        1 0.50 0.94
3        1 0.75 0.78
4        1 1.00 0.48
5        1 1.25 0.37
6        1 2.00 0.19
7        1 3.00 0.12
8        1 4.00 0.11
9        1 5.00 0.08
10       1 6.00 0.07
11       1 8.00 0.05
12       2 0.25 2.03
13       2 0.50 1.63
14       2 0.75 0.71
15       2 1.00 0.70
16       2 1.25 0.64
17       2 2.00 0.36
18       2 3.00 0.32
19       2 4.00 0.20
20       2 5.00 0.25
21       2 6.00 0.12
22       2 8.00 0.08
23       3 0.25 2.72
24       3 0.50 1.49
25       3 0.75 1.16
26       3 1.00 0.80
27       3 1.25 0.80
28       3 2.00 0.39
29       3 3.00 0.22
30       3 4.00 0.12
31       3 5.00 0.11
```

```
32        3 6.00 0.08
33        3 8.00 0.08
34        4 0.25 1.85
35        4 0.50 1.39
36        4 0.75 1.02
37        4 1.00 0.89
38        4 1.25 0.59
39        4 2.00 0.40
40        4 3.00 0.16
41        4 4.00 0.11
42        4 5.00 0.10
43        4 6.00 0.07
44        4 8.00 0.07
45        5 0.25 2.05
46        5 0.50 1.04
47        5 0.75 0.81
48        5 1.00 0.39
49        5 1.25 0.30
50        5 2.00 0.23
51        5 3.00 0.13
52        5 4.00 0.11
53        5 5.00 0.08
54        5 6.00 0.10
55        5 8.00 0.06
56        6 0.25 2.31
57        6 0.50 1.44
58        6 0.75 1.03
59        6 1.00 0.84
60        6 1.25 0.64
61        6 2.00 0.42
62        6 3.00 0.24
63        6 4.00 0.17
64        6 5.00 0.13
65        6 6.00 0.10
66        6 8.00 0.09
```

Ai sei soggetti era stata somministrata una identica quantità di indometacina, allo scopo di determinare la velocità alla quale il farmaco viene eliminato: un dato necessario per stabilire posologia e intervalli di somministrazione.

Ora copiate e incollate nella `Console di R` questo script e premete ↵ `Invio`.

```
# GRAFICO A LINEE con ggplot
#
library(ggplot2) # carica il pacchetto per la grafica
#
# realizza il grafico a linee per ciascuno dei sei soggetti
#
ggplot(data=Indometh, aes(x=time, y=conc, group=Subject,
color=Subject, linetype=Subject, shape=Subject)) + geom_line() + geom_point() +
theme_classic()
#
```

Il grafico risultante

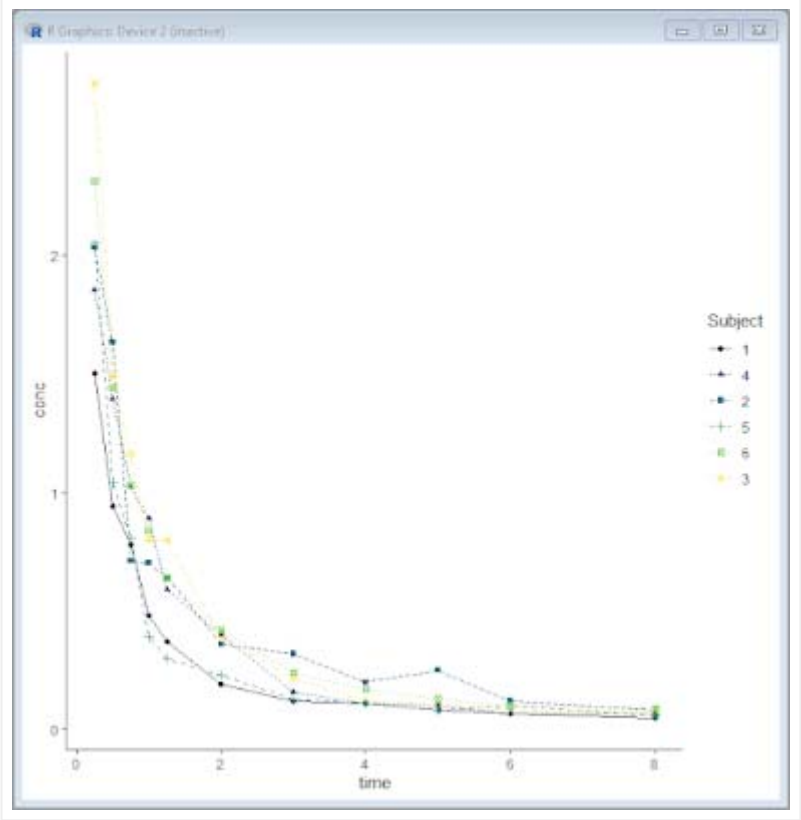

viene quindi realizzato:
→ specificando l'origine dei dati (**Indometh**);
→ riportando in ascisse il tempo (**time**) e in ordinate la concentrazione (**conc**);
→ aggregando i dati per soggetto (**group=Subject**);
→ impiegando per ciascun soggetto (**Subject**) un differente colore (**color**), linea (**linetype**) e simbolo (**shape**);
→ riportando sul grafico i punti (**geom_point**) e le linee (**geom_line**) che li uniscono.

Niente di più facile per produrre una versione base del grafico, anche se ovviamente è poi possibile aggiustare a piacere colori, dimensione dei simboli, spessore e tipo delle linee, legenda e quant'altro: esempi si trovano anche in altri post di questo sito [2], ma ovviamente raccomando comunque di scaricare e tenere a portata di mano il manuale di riferimento del pacchetto [3]. Da notare infine che il messaggio che si vede comparire

```
Messaggio di avvertimento:
Using shapes for an ordinal variable is not advised
```

è semplicemente un suggerimento e può essere ignorato.

Ora, visto l'andamento simile delle sei curve di eliminazione del farmaco, l'idea è di realizzare un grafico che riporti per ciascuno dei tempi la media delle concentrazioni rilevate nei sei soggetti e i suoi limiti di confidenza al 95%, rappresentati dalla media +1.96 volte l'errore standard (es) e dalla media -1.96 volte l'errore standard. Per questo copiate e incollate nella `Console di R` queste righe e premete ↵ `Invio`.

#
library(plotrix) # carica il pacchetto per il calcolo dell'errore standard
#
aggrega i dati per ciascun tempo e calcola media ed errore standard della concentrazione per ciascun tempo
#
mydata <- aggregate(conc~time, data=Indometh, FUN=function(x) c(mean=mean(x), se=std.error(x)))
#
mydata # mostra i dati calcolati
#
media <- mydata$conc[,1] # salva in un vettore le medie calcolate
es <- mydata$conc[,2] # salva in un vettore gli errori standard calcolati
#

Come si vede:
→ serve il pacchetto **plotrix**, che deve essere preventivamente installato e che fornisce la funzione **std.error()** per calcolare l'errore standard della media;
→ con la funzione **aggregate()** sono aggregate le concentrazioni del farmaco rilevate nei sei soggetti a ciascun tempo (**conc~time**);
→ con **FUN=function(x)** sono calcolati sui sei valori di concentrazione rilevati a ciascun tempo la media **mean(x)** e l'errore standard **std.err(x)**;
→ per semplificare e rendere più leggibile il codice successivo media (`conc.mean`) ed errore standard (`conc.se`) sono salvati rispettivamente nel vettore **media** e nel vettore **es**.

Questi sono i dati calcolati che troviamo in **mydata**

```
> mydata # mostra i dati calcolati
   time   conc.mean     conc.se
1  0.25 2.076666667 0.168832593
2  0.50 1.321666667 0.110616957
3  0.75 0.918333333 0.071991512
4  1.00 0.683333333 0.083373324
5  1.25 0.556666667 0.076361712
6  2.00 0.331666667 0.039616214
7  3.00 0.198333333 0.031242777
8  4.00 0.136666667 0.015846486
9  5.00 0.125000000 0.026172505
10 6.00 0.090000000 0.008164966
11 8.00 0.071666667 0.006009252
```

Dopo questo necessario passo intermedio possiamo di nuovo tornare alla rappresentazione del grafico a linee, copiate e incollate nella `Console di R` queste ultime righe di codice e premete `↵ Invio`.

#
windows() # apre e inizializza una nuova finestra grafica
#
realizza il grafico a linee riportando per ciascun tempo i limiti di confidenza al 95% della media
#
ggplot(data=mydata, aes(x=time, y=media)) + geom_line() + geom_point() + theme_classic() + geom_errorbar(aes(ymin=media-1.96*es, ymax=media+1.96*es), width=.1)
#

Dopo avere aperto con **windows()** una nuova finestra grafica vediamo che la novità rispetto al grafico a linee iniziale, a parte rappresentare in ordinate per ciascun tempo non più i singoli valori di

concentrazione bensì la loro **media** ricavata dalla tabella **mydata**, è rappresentata dalla funzione **geom_errorbar()** che con gli argomenti **ymin** e **ymax** provvede ad aggiungere al grafico per ciascun tempo i limiti di confidenza al 95% della media, calcolati sottraendo e sommando alla **media** l'errore standard **es** moltiplicato per **1.96**.

Ed ecco il grafico risultante che, vale la pena di sottolinearlo, fornisce una chiave di lettura cruciale per l'interpretazione dei risultati in quanto di ciascuna media riporta il grado di incertezza.

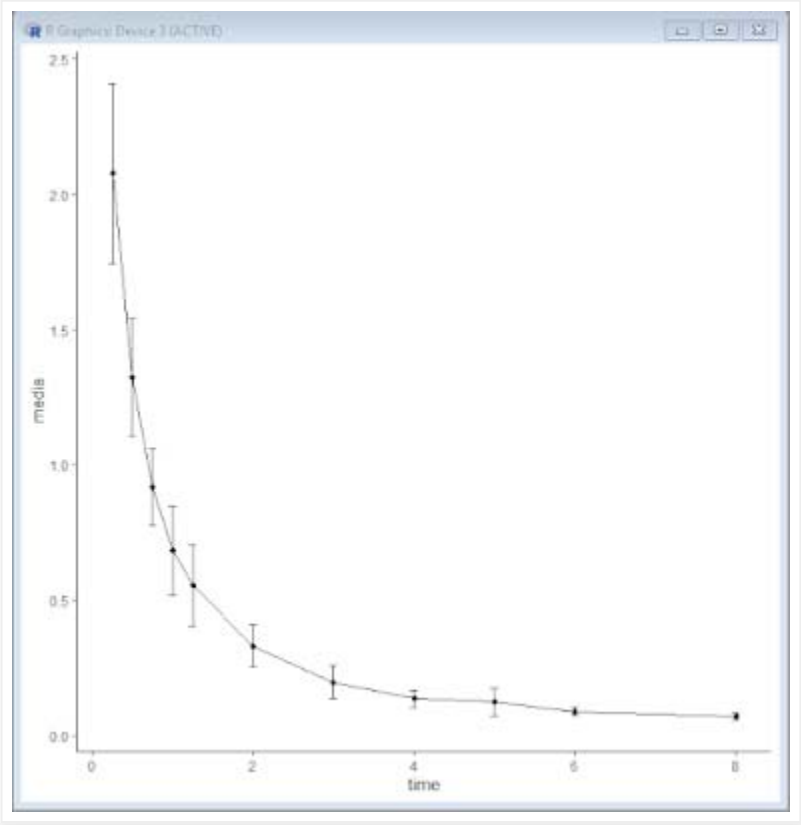

Conclusione: anche nel caso assai semplice di un grafico a linee – che come detto può essere realizzato con le *funzioni base* di **R** [1], ma sicuramente con maggior difficoltà – il pacchetto **ggplot2** fornisce un esempio di versatilità, di rapidità di realizzazione e di ottimi risultati grafici: quanto di meglio per essere invogliati al suo impiego e al suo approfondimento [3].

---

[1] Vedere il post Grafici a linee.

[2] Fate click su ggplot2 nelle **Parole chiave** o digitate ggplot2 nella casella **Cerca nel blog** quindi fate click su Cerca.

[3] Vedere il link al manuale di riferimento su:
https://cran.r-project.org/web/packages/ggplot2/index.html