Grafici a violino (violin plot) con ggplot

I **grafici a violino (violin plot)** prendono lo spunto dai grafici a scatola con i baffi (boxplot) riportando per una distribuzione univariata, al posto delle classiche scatole, il profilo di densità dei valori osservati sotto forma di kernel density plot [1].

La forma tipica dei grafici, che dà loro il nome, deriva dal fatto che il kernel density plot dei dati è riportato simmetricamente da entrambi i lati della distribuzione. Mentre interessante, come vedremo tra poco, è che a un violin plot possono essere sovrapposti al bisogno un *grafico a scatola con i baffi (boxplot)* [2] oppure un *grafico a punti (dotplot)* [3], a testimonianza del fatto che si tratta di viste dei dati diverse ma tra loro integrate e complementari.

Come dati impieghiamo la concentrazione degli eritrociti (globuli rossi) nel sangue rilevata in 202 atleti australiani riportata nella colonna/variabile **rcc** della tabella **ais** inclusa nel pacchetto **DAAG**. Accertatevi di avere installato il pacchetto o in alternativa procedete come indicato in [4]. Se non volete installare il pacchetto e avete scaricato il file di dati `ais.csv` sostituite nella prima riga dello script

```
library(DAAG)
```

con

```
ais <- read.table("c:/Rdati/ais.csv", header=TRUE, sep=";", dec=",")
```

Dovete scaricare dal **CRAN** anche il pacchetto **ggplot2** che realizza la grafica [5].

Il tema è stato suddiviso in sei script, corrispondenti ad altrettanti modi di rappresentazione, tra i quali scegliere quello preferito. Copiate questo primo script, incollatelo nella `Console di R` e premete `↵ Invio`.

```
# GRAFICI A VIOLINO (VIOLIN PLOT)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto necessario per la grafica
windows() # apre una nuova finestra
#
# violin plot riportati per intero
ggplot(ais, aes(x=sport, y=rcc, fill=sport)) + geom_violin(trim=FALSE)
#
```

La seconda riga di codice con **library(ggplot2)** carica il pacchetto che contiene le funzioni necessarie per realizzare i grafici a violino (violin plot).

Dopo (terza riga) avere aperto e inizializzato con la funzione **windows()** una nuova finestra grafica, arriviamo finalmente all'unica riga di codice necessaria per realizzare il nostro primo grafico a violino mediante due funzioni concatenate:
→ la funzione **ggplot()** che specifica come primo argomento i dati da impiegare (**ais**) e come secondo argomento impiega la funzione **aes()** per realizzare il grafico per la variabile eritrociti (**y=rcc**) separatamente per ciascuno sport praticato (**x=sport**), riempiendo i grafici con un colore differente per ciascuno sport (**fill=sport**);
→ la funzione **geom_violin** che realizza il grafico riportando per intero il kernel density plot calcolato sui dati.

Questo è quindi il primo grafico:

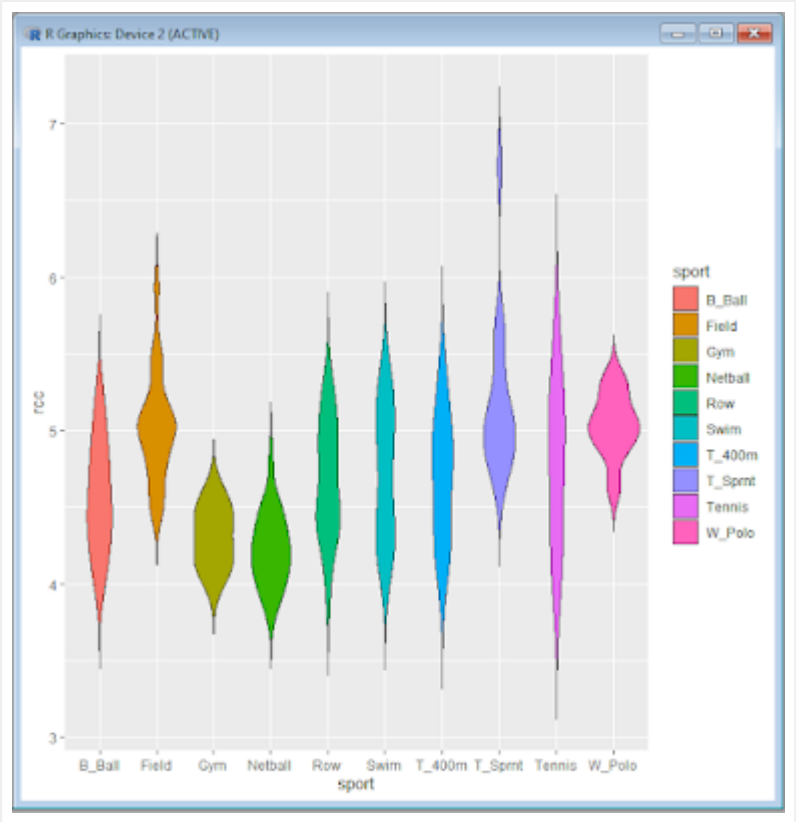

Minimizzate la finestra ma non chiudetela: vi sarà utile riaprirla per confrontare questo primo grafico con il secondo e con i successivi grafici.

Ora copiate e incollate nella `Console di R` il secondo script e premete `↵ Invio`.

```
# GRAFICI A VIOLINO (VIOLIN PLOT)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto necessario per la grafica
windows() # apre una nuova finestra
#
# violin plot troncati ai valori minimo e massimo osservati
ggplot(ais, aes(x=sport, y=rcc, fill=sport)) + geom_violin(trim=TRUE)
#
```

Ponendo nella funzione **geom_violin()** l'argomento **trim=TRUE** il kernel density plot/violin plot viene ora *troncato* in corrispondenza del valore minimo e del valore massimo osservati, o se preferite viene *tracciato solamente* all'interno del range/intervallo dei valori osservati.

Questo corrisponde ad una regola aurea in quanto in statistica (ma non solo in statistica) effettuare una estrapolazione, ovvero andare oltre i dati, quindi andare al di la dell'informazione in nostro possesso, significa addentrarsi in un terreno molto scivoloso.

Ed ecco il secondo grafico:

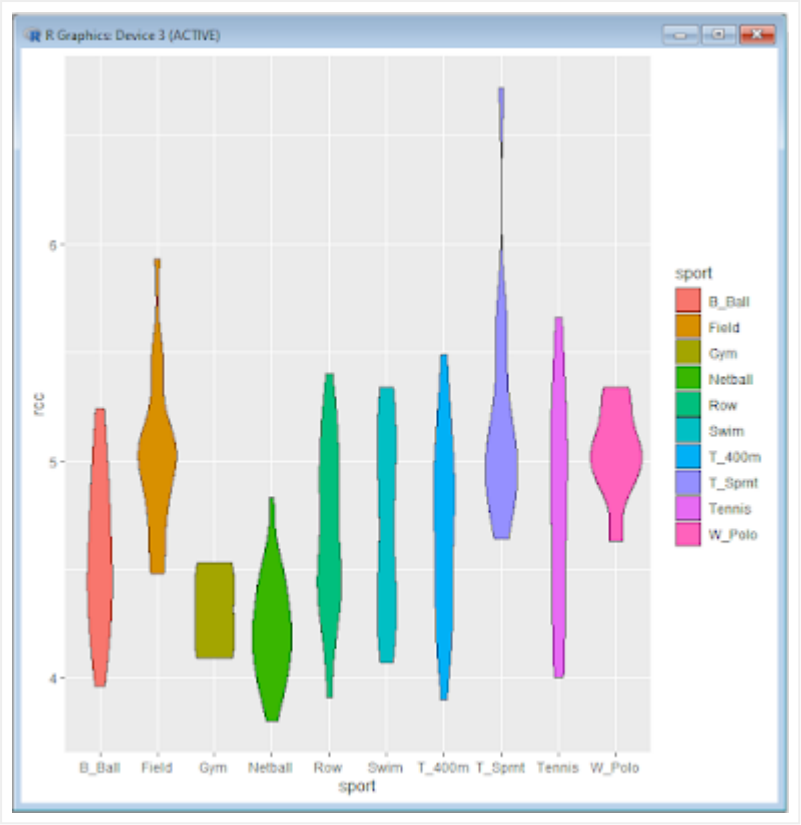

Ora copiate e incollate nella `Console di R` questo terzo script e premete ↵ `Invio`.

GRAFICI A VIOLINO (VIOLIN PLOT)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto necessario per la grafica
windows() # apre una nuova finestra
#
violin plot con sovrapposto grafico a scatola con i baffi
ggplot(ais, aes(x=sport, y=rcc, fill=sport)) + geom_violin(trim=TRUE) + geom_boxplot(width=0.1, fill="white")
#

Qui è stata aggiunta la funzione **geom_boxplot()** che sovrappone al grafico a violino/violin plot un *grafico a scatola con i baffi (boxplot)* specificando di rappresentare le scatole dei grafici:
→ con **width="0.1"** che definisce la larghezza delle scatole/box;
→ con **fill="white"** che specifica il colore di riempimento delle scatole/box.

Da notare che sono stati impiegati gli stessi dati utilizzati nell'esempio che illustra i grafici a scatola con i baffi [2] proprio per consentirvi di effettuare un immediato confronto tra le due rappresentazioni grafiche.

Questo è il terzo grafico realizzato:

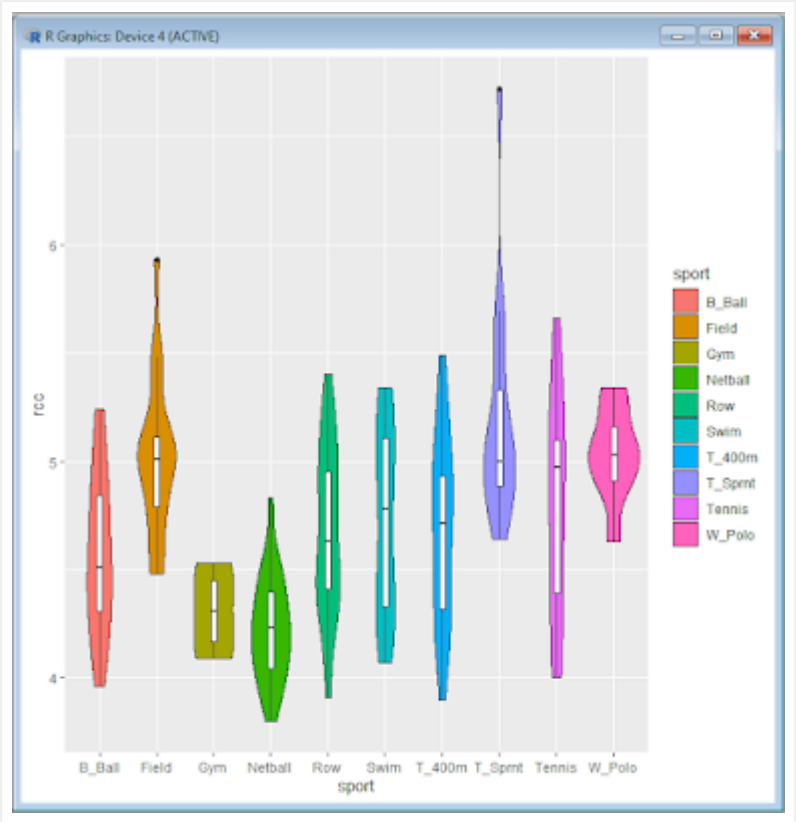

Copiate e incollate nella `Console di R` il quarto script e premete ↵ `Invio`.

```
# GRAFICI A VIOLINO (VIOLIN PLOT)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto necessario per la grafica
windows() # apre una nuova finestra
#
# violin plot senza legenda
ggplot(ais, aes(x=sport, y=rcc, fill=sport)) + geom_violin(trim=TRUE) +
geom_boxplot(width=0.1, fill="white") + theme(legend.position="none")
#
```

Questa volta aggiungendo **theme(legend.position="none")** abbiamo tolto, in quanto ridondante, la legenda generata automaticamente che compariva sulla destra.

Questo è conseguentemente il quarto grafico:

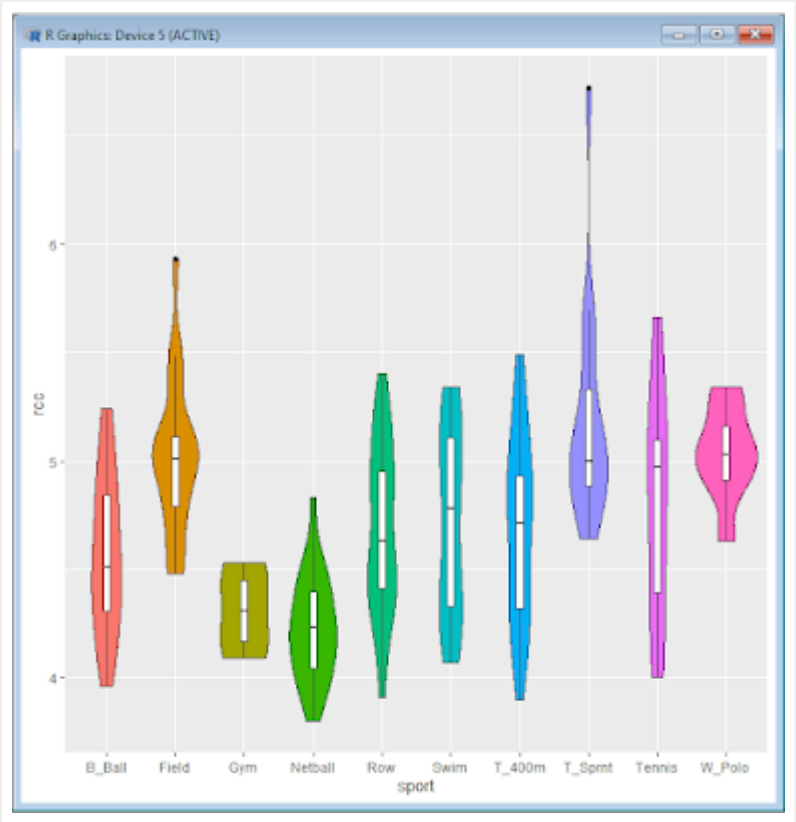

Copiate e incollate nella `Console di R` questo quinto script e premete ↵ `Invio`.

GRAFICI A VIOLINO (VIOLIN PLOT)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto necessario per la grafica
windows() # apre una nuova finestra
#
violin plot con titolo ed etichette degli assi
ggplot(ais, aes(x=sport, y=rcc, fill=sport)) + geom_violin(trim=TRUE) + geom_boxplot(width=0.1, fill="white") + theme(legend.position="none") + labs(title="Concentrazione degli eritrociti per sport praticato", x="Sport", y = "Concentrazione degli eritrociti (10^12/L)")
#

Ogni grafico che si rispetti prevede un titolo e la descrizione della variabili rappresentate, cosa che viene qui realizzata con la funzione **labs()** nella quale sono specificati titolo (**title=...**), etichetta dell'asse delle x (**x=...**) ed etichetta dell'asse delle y (**y=...**).

Questo è il relativo e quinto grafico:

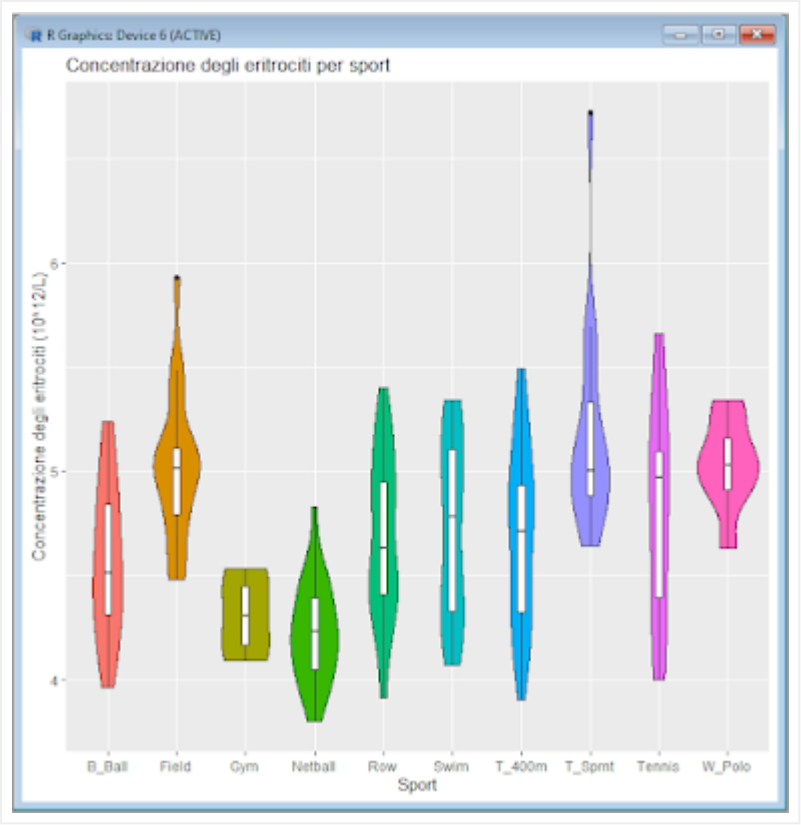

Per l'ultimo script copiate e incollate nella `Console di R` il codice che segue e premete ↵ `Invio`.

```
# GRAFICI A VIOLINO (VIOLIN PLOT)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(ggplot2) # carica il pacchetto necessario per la grafica
windows() # apre una nuova finestra
#
# violin plot con sovrapposto il grafico a punti
ggplot(ais, aes(x=sport, y=hg, fill=sport)) + geom_violin(trim=TRUE) +
geom_dotplot(method="dotdensity", binaxis='y', stackdir="center", stackratio=1,
dotsize=0.7, binwidth=0.2, show.legend=FALSE) + coord_cartesian(ylim=c(10,20)) +
theme(legend.position="none") + labs(title="Concentrazione dell'emoglobina nel sangue
per sport praticato", x="Sport praticato", y="Emoglobina (g/dL)")
#
```

Qui è stata aggiunta la funzione **geom_dotplot()** che sovrappone al grafico a violino/violin plot un *grafico a punti (dotplot)*. Inoltre i dati sono cambiati: abbiamo riportato, per ciascuno sport praticato, la concentrazione dell'emoglobina, la stessa impiegata per realizzare i grafici a punti [3], per consentirvi di effettuare un immediato confronto tra le due rappresentazioni grafiche.

Infine è stata aggiunta la funzione **coord_cartesian()** mediante la quale sono fissati con l'argomento **ylim=...** il limite inferiore (**10**) e il limite superiore (**20**) entro i quali rappresentare i valori.

E questo è quindi il sesto e ultimo grafico:

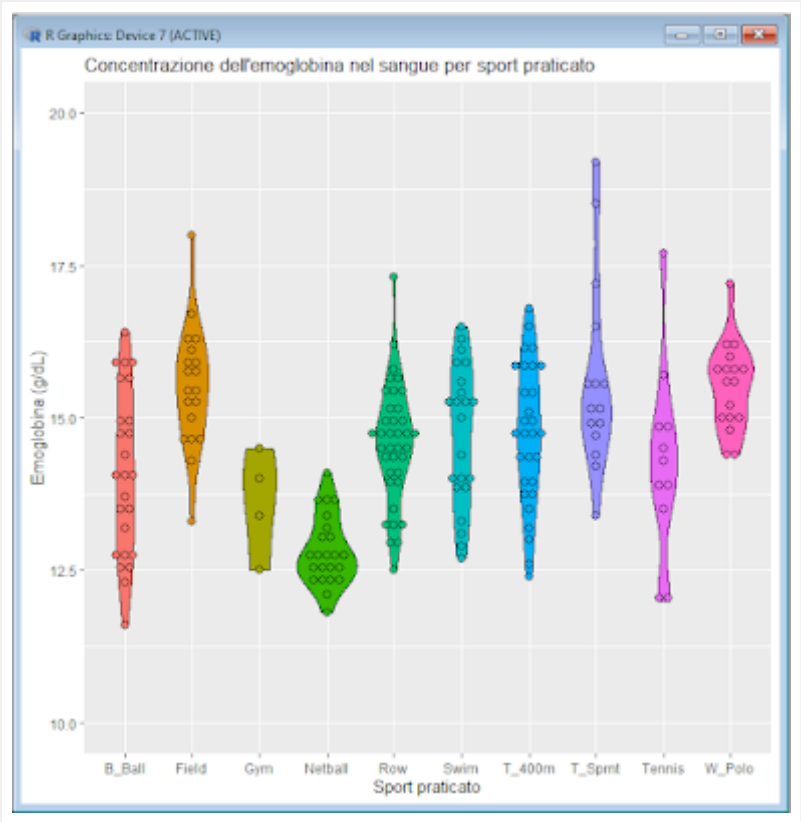

Potete facilmente adattare il codice per ottenere la rappresentazione che più vi interessa, aiutandovi con la documentazione del pacchetto [5]:
→ sostituendo la prima riga con il codice necessario per importare i vostri dati;
→ nella funzione **ggplot()** sostituendo **ais** con il nome dell'oggetto che contiene i vostri dati;
→ riportando in **x=...** il nome del *fattore* cioè della variabile qualitativa con la quale aggregare i dati in sottoinsiemi e in **y=...** il nome della vostra variabile numerica;
→ adattando opportunamente nella funzione **labs()** il titolo, il nome del fattore e il nome della variabile.

Per una guida rapida all'importazione in **R** dei vostri dati potete consultare i link:
→ importazione dei dati da un file .xls o .xlsx
→ importazione dei dati da un file .csv

Infine si rammenta che nel post Salvare i grafici di R in un file è riportato uno script che consente di trasformare i grafici in immagini e salvarli sotto forma di file `.bmp`, `.jpeg`, `.png`, `.pdf`, `.ps` per poterli stampare, archiviare, inserire in una pubblicazione, in un post o in un sito web.

---

[1] Per i dettagli vedere il post Kernel density plot.

[2] Vedere il post Grafici a scatola con i baffi (boxplot).

[3] Vedere il post Grafici a punti (dotplot).

[4] Potete scaricare questo e gli altri file di dati seguendo le indicazioni che trovate alla pagina Dati.

[5] Il manuale di riferimento *Package 'ggplot2'* lo potete scaricare facendo click sul link accanto alla voce *Reference manual* nella pagina di documentazione del pacchetto.
https://cran.r-project.org/web/packages/ggplot2/index.html